PENGENALAN WAJAH ANXIETY MENGGUNAKAN METODE PHASE ONLY CORRELATION WITH ALL BLOCK SEARCH DAN MODEL ARSITEKTUR TABULAR RETRIEVAL NETWORK

PROPOSAL SKRIPSI

Oleh:

SYAHRUL BHUDI FERDIANSYAH NIM. 2241720167

PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNOLOGI INFORMASI

POLITEKNIK NEGERI MALANG

2026

DAFTAR ISI

DAFTAR ISI I

DAFTAR GAMBAR III

DAFTAR TABEL IV

BAB I. PENDAHULUAN 1

1.1 Latar Belakang 1

1.2 Rumusan Masalah 3

1.3 Batasan Masalah 4

1.4 Tujuan 5

1.5 Manfaat 5

BAB II. LANDASAN TEORI 7

2.1 Studi Literatur 7

2.2 Dasar Teori 9

2.2.1 Ekspresi Wajah 9

2.2.2 Ekspresi Mikro (*Micro Expression*) 10

2.2.3 Gangguan Kecemasan (*Anxiety Disorder*) 11

2.2.4 Pengolahan Citra (*Image Processing*) 13

2.2.5 Deteksi Wajah 13

2.2.6 Dlib 14

2.2.7 *Phase Only Correlation with All Block Search* (POC-ABS) 15

2.2.8 Data Tabular 24

2.2.9 *Facebook AI Similarity Search* (FAISS) 25

2.2.10 *Tabular Retrieval Network* (TabR) 26

2.2.11 *Confussion Matrix* 29

BAB III. METODOLOGI PENELITIAN 33
3.1 Waktu dan Tempat Penelitian 33
3.2 Teknik Pengumpulan Data 33
3.3 Teknik Pengolahan Data 39
3.4 Desain Sistem 40
3.4.1 Pembuatan Model 43
3.4.2 Evaluasi Model 47
3.4.3 Arsitektur Sistem 48
3.4.4 Alur Proses Sistem 50
3.5 Uji Coba Sistem 51
DAFTAR LAMPIRAN VI

DAFTAR GAMBAR

Gambar 2.1 Ekspresi Wajah 10
Gambar 2.2 *Micro-expressions* 10
Gambar 2.3 *Facial Landmark* Dlib 15
Gambar 2.4 Contoh dua frame untuk n1 dan n2 16
Gambar 2.5 Proses POC deteksi pergerakan dari gambar contoh 2.2 20
Gambar 2.6 Arsitektur TabR 27
Gambar 2.7 Encoder dan Decoder 28
Gambar 2.8 Retreival Module 29
Gambar 2.9 Gambar Confusion Matrix 31
Gambar 3.1 Alur Pengumpulan Data Primer Penelitian 34
Gambar 3.2 Proses pengambilan data 38
Gambar 3.3 contoh Dataset dalam bentuk *frame* 38
Gambar 3.4 Desain Sistem 40
Gambar 3.5 Deteksi 68 *Facial Landmark* menggunakan Dlib 41
Gambar 3.6 Hasil *cropping* area mata-alis kanan, mata-alis kiri, dan mulut 42
Gambar 3.7 Alur model TabR 44
Gambar 3.8 Proses *Context Freezing* 46
Gambar 3.9 Diagram Alur 50

DAFTAR TABEL

Tabel 2.1 Penelitian Terakhir 7
Tabel 2.2 Contoh hasil ekstraksi fitur 24
Tabel 3.1 Kategorisasi dan skor 39
Tabel 3.2 Contoh bentuk hasil data 42

BAB I. PENDAHULUAN

1.1 Latar Belakang

Ekspresi wajah merupakan salah satu bentuk komunikasi yang paling kuat dan universal, serta sangat terkait dengan kondisi mental, sikap, dan niat seseorang. Di samping ekspresi wajah biasa (*macro-expressions*) yang umum terlihat sehari-hari, emosi juga dapat muncul dalam bentuk khusus ketika seseorang berada pada kondisi tertentu, yaitu *micro-expressions* (Li dkk., 2022). *Micro-expressions* merupakan gerakan wajah yang sangat singkat dan tidak disengaja ketika seseorang berusaha menekan atau menyembunyikan emosi sebenarnya, sehingga memberikan gambaran yang lebih autentik dibandingkan *macro-expressions* yang dapat disamarkan (J. Chen dkk., 2025). Dalam konteks kategorisasi ekspresi wajah, terdapat berbagai model yang pada umumnya merujuk pada emosi dasar yang diperkenalkan oleh Ekman (1992), di mana tipe emosi primer dalam model-model yang banyak digunakan terdiri dari lima, enam, atau tujuh kategori, mencakup *happiness, sadness, anger, disgust, surprise,* dan *fear* (Coppini dkk., 2023). Dalam konteks ini, *micro-expressions* menjadi relevan untuk dikaji lebih lanjut ketika dikaitkan dengan emosi kompleks seperti *anxiety*.

Secara psikologis, anxiety berbeda dari fear karena dipicu oleh ancaman yang tidak pasti dan memunculkan kewaspadaan berkelanjutan, sedangkan *fear* berkaitan dengan ancaman yang jelas dan langsung (American Psychiatric Association, 2022; Watson dkk., 2022). Dalam konteks sosial, individu dengan anxiety cenderung mengendalikan ekspresi emosinya, sehingga sinyal visual kecemasan jarang muncul secara eksplisit dan lebih sering termanifestasi sebagai gerakan wajah yang tidak disengaja, sangat halus, dan berlangsung singkat, selaras dengan karakteristik micro-*expressions* (Lei dkk., 2024; Zhao dkk., 2023). Kondisi ini menjadikan pengenalan *anxiety* sebagai tantangan visual yang bersifat *spasio-temporal* karena informasi penting terletak pada dinamika pergerakan antar *frame*. Namun, pengembangan model pengenalan *micro-expression* masih terkendala keterbatasan data dan anotasi, di mana mayoritas dataset standar

mengadopsi taksonomi emosi dasar tanpa label *anxiety* eksplisit (Zhang dkk., 2022). Keterbatasan ini memaksa emosi kompleks seperti *anxiety* untuk dilebur ke dalam kelas general *'Others'*, yang pada dataset standar seperti CASME II terbukti menampung proporsi sampel sangat signifikan hingga mencapai 41,3% (Ben dkk., 2021), sehingga karakteristik visual anxiety menjadi tidak terdefinisi dengan jelas dan menyulitkan pembelajaran representasi yang spesifik dan robust (Zhao dkk., 2023). Oleh karena itu, pengumpulan dan anotasi data *micro-expression* secara mandiri menjadi penting untuk memperoleh representasi *anxiety* yang lebih terkontrol, dengan prosedur pengambilan dan pelabelan dijelaskan pada bagian metodologi.

Sejalan dengan keterbatasan anotasi tersebut, pengembangan metode dalam penelitian *micro-expression* selama ini masih berfokus pada emosi dasar yang telah tersedia dalam dataset standar. Penelitian SOTA umumnya berfokus pada peningkatan akurasi emosi dasar melalui pengembangan arsitektur *spatiotemporal* dan mekanisme atensi, dengan evaluasi pada dataset seperti CASME II, SAMM, dan SMIC yang masih mengadopsi taksonomi emosi dasar (Bin Talib dkk., 2025; Li dkk., 2025). Meskipun pendekatan SOTA mampu mencapai performa tinggi pada klasifikasi emosi dasar, pendekatan tersebut secara konseptual masih dibatasi oleh asumsi emosi dasar yang mendasari anotasi dataset. Hal ini menjadikan pendekatan berbasis emosi dasar kurang sesuai untuk mengkaji *anxiety* yang bersifat implisit dan tidak terdefinisi dalam taksonomi dataset standar, sehingga menegaskan adanya celah metodologis dalam pengkajian *micro-expression anxiety*.

Perkembangan penelitian *anxiety* dalam beberapa tahun terakhir menunjukkan pergeseran dari pendekatan subjektif berbasis kuesioner dan wawancara klinis menuju pendekatan objektif berbasis analisis sinyal visual, sekaligus mencerminkan perubahan cara pandang terhadap *anxiety* yang tidak lagi diperlakukan sebagai kategori emosi diskrit, melainkan sebagai kondisi psikologis yang terefleksi melalui pola perilaku dan dinamika ekspresi wajah yang bersifat halus dan berkelanjutan, khususnya

melalui analisis perubahan mikro antar-frame pada data ekspresi wajah berbasis video (S. Chen dkk., 2025; Ghafarfaraji, 2025). Pergeseran ini didorong oleh keterbatasan metode subjektif yang rentan terhadap bias pelaporan, keterlambatan evaluasi, serta kecenderungan individu dengan *anxiety* untuk menyamarkan kondisi emosionalnya (S. Chen dkk., 2025). Oleh karena itu, pendekatan pengenalan wajah yang memodelkan *anxiety* sebagai pola pergerakan mikro wajah secara *spasio-temporal* menjadi semakin relevan untuk menghasilkan representasi yang lebih valid dan kontekstual.

Untuk menjawab celah penelitian tersebut, penelitian ini mengusulkan pendekatan representasi pergerakan mikro-wajah yang memodelkan *anxiety* berdasarkan karakteristik pergerakan antar-frame (spasio-temporal), bukan berdasarkan kategori emosi dataset standar. *Phase Only Correlation with All Block Search* (POC-ABS) digunakan untuk mengekstraksi pergeseran mikro antar-frame secara eksplisit melalui analisis fase, sehingga mampu menangkap kebocoran gerak halus yang muncul ketika emosi ditekan (Rosiani dkk., 2020). Hasil ekstraksi menggunakan metode POC-ABS berupa nilai-nilai numerik yang merepresentasikan arah dan besar pergerakan mikro wajah pada setiap area pengamatan. Dengan demikian, setiap sampel ekspresi wajah direpresentasikan sebagai sekumpulan fitur numerik yang terstruktur, sehingga proses klasifikasi difokuskan pada pembedaan pola pergerakan mikro antar-sampel. Representasi pergerakan tersebut selanjutnya dimodelkan menggunakan arsitektur *Tabular Retrieval Network* (TabR), yang dirancang untuk menangani data *tabular* dan memanfaatkan hubungan kedekatan antar-sampel dalam proses klasifikasi (Pasaribu dkk., 2024).

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, dapat diidentifikasi beberapa permasalahan penelitian sebagai berikut:

1. Bagaimana fitur pergerakan halus pada area wajah yang diekstraksi menggunakan metode POC-ABS mampu membedakan kondisi *anxiety* dan tidak *anxiety* ?

2. Bagaimana performa model TabR dalam mengklasifikasikan kondisi *anxiety* dan tidak *anxiety* berdasarkan fitur POC-ABS yang diekstraksi dari data penelitian ?
3. Bagaimana hasil evaluasi kinerja model klasifikasi yang diusulkan berdasarkan metrik akurasi, *precision*, *recall*, dan F1-score ?

1.3 Batasan Masalah

Agar penelitian ini lebih terarah dan fokus, maka penulis menetapkan batasan-batasan masalah sebagai berikut:

1. **Dataset:** Penelitian ini menggunakan dataset *micro-expression anxiety* yang dikumpulkan secara mandiri melalui skema pre–post situasi ujian dengan dukungan kuesioner, pengelompokan label tingkat kecemasan (*anxiety*) berdasarkan oleh pakar Prof. Dr. Adi Atmoko, M.Pd., seorang dosen dari Fakultas Ilmu Pendidikan yang memiliki keahlian di bidang bimbingan dan konseling..
2. **Fokus Representasi Emosi:** Penelitian ini difokuskan pada pengenalan kondisi *anxiety* dan tidak *anxiety*, tanpa mengacu pada taksonomi emosi dasar seperti *happiness, anger, fear,* dan emosi dasar lainnya.
3. **Ekstraksi Pergerakan Mikro Wajah:** Ekstraksi pergerakan mikro wajah dibatasi pada penggunaan metode *Phase Only Correlation with All Block Search (POC-ABS)* untuk merepresentasikan pergeseran mikro antar-frame, tanpa membandingkan dengan metode ekstraksi gerakan lainnya.
4. **Area Pengamatan:** Penelitian hanya difokuskan untuk mengamati dan mengambil nilai pada area mata-alis kanan, mata-alis kiri, dan mulut
5. **Model Klasifikasi:** Pemodelan dan klasifikasi data dilakukan menggunakan *Tabular Retrieval Network (TabR)* berbasis data tabular, tanpa membahas atau membandingkan dengan model deep learning lain seperti CNN atau transformer berbasis citra.

6. **Ruang Lingkup Sistem dan Evaluasi:** Penelitian ini dibatasi pada pemrosesan data citra wajah dan evaluasi performa model menggunakan metrik Accuracy, Precision, Recall, dan F1-Score.

1.4 Tujuan

Berdasarkan rumusan masalah di atas, tujuan dari penelitian ini adalah:

1. Dapat mengidentifikasi dan menganalisis kemampuan fitur pergerakan halus pada area wajah yang diekstraksi menggunakan metode POC-ABS dalam membedakan kondisi *anxiety* dan tidak *anxiety*.
2. Dapat mengevaluasi performa model TabR dalam mengklasifikasikan kondisi *anxiety* dan tidak *anxiety* berdasarkan fitur POC-ABS yang diekstraksi dari data penelitian.
3. Dapat mengevaluasi kinerja model klasifikasi yang diusulkan berdasarkan metrik akurasi, precision, recall, dan F1-score.

1.5 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. **Kontribusi terhadap Analisis *Anxiety* Berbasis Ekspresi Wajah**
   Penelitian ini memberikan kontribusi dalam pengembangan analisis *micro-expression anxiety* pada wajah yang belum banyak dikaji secara eksplisit dalam penelitian *micro-expression* sebelumnya.
2. **Referensi Pengembangan Dataset *Micro-Expression Anxiety***
   Dataset *pre–post exam* yang dikumpulkan secara mandiri melalui pengisian kuesioner dan perekaman ekspresi wajah dapat menjadi referensi awal bagi penelitian selanjutnya dalam membangun dan mengolah data *micro-expression anxiety* yang bersifat natural dan kontekstual.
3. **Pendekatan Teknis untuk Deteksi *Micro-Expression Anxiety***
   Pendekatan teknis yang mengombinasikan ekstraksi pergerakan mikro wajah menggunakan *Phase Only Correlation with All Block Search (POC-ABS)* dan pemodelan klasifikasi berbasis data tabular menggunakan *Tabular Retrieval Network (TabR)* dapat menjadi

acuan metodologis bagi penelitian selanjutnya dalam mendeteksi emosi wajah yang bersifat halus dan sulit diamati secara visual.

BAB II. LANDASAN TEORI

2.1 Studi Literatur

Beberapa Penelitian yang dijadikan rujukan dalam penelitian ini adalah sebagai berikut:

Tabel 2.1 Penelitian Terakhir

Judul Jurnal	Tahun	Metode	Hasil Penelitian
A Novel Approach on Motion Estimation for Micro-Expression Recognition Using Phase Only Correlation with All Block Search (POC-ABS) (Rosiani dkk., 2020)	2020	POC-ABS dan SVM	Metode POC-ABS efektif dalam menangkap pergerakan mikro-ekspresi yang sangat halus secara cepat dan presisi, khususnya pada area alis yang menjadi indikator utama kebocoran ekspresi. Dengan rata-rata waktu komputasi sekitar 0,03 detik serta tingkat akurasi yang tinggi ketika dikombinasikan dengan klasifier SVM dan KNN, metode ini dinilai sesuai untuk penerapan pengenalan mikro-ekspresi secara real-time.
TabNet: Attentive Interpretable Tabular Learning (Arik dkk., 2021)	2021	TabNet	TabNet menunjukkan performa kompetitif pada data tabular, dengan akurasi hingga 96,99% pada beberapa dataset tabular dan peningkatan

			konsisten dibanding metode tree-based, sambil mempertahankan interpretabilitas berbasis seleksi fitur bertahap.
Micro-expression recognition model based on TV-L1 optical flow method and improved ShuffleNet (Liu dkk., 2022)	2022	TV-L1 *Optical Flow*, ShuffleNetV2	Model TV-L1 optical flow dengan ShuffleNetV2 dan improved ViT mencapai UAR ≈0,70 dan UF1 ≈0,73 secara konsisten pada berbagai dataset *micro-expression*, dengan waktu inferensi sekitar 37,9 ms per sampel.
TabR: Tabular Deep Learning Meets Nearest Neighbors (Gorishniy dkk., 2024)	2024	TabR	Pada *benchmark* OpenML-CC18, TabR menunjukkan peringkat rata-rata terbaik di antara model *deep learning* tabular dan pada sejumlah dataset melampaui GBDT, terutama pada skenario data kecil hingga menengah.
Tabular Data Classification and Regression: XGBoost or Deep Learning with Retrieval-Augmented Generation (Pasaribu dkk., 2024)	2024	XGBoost, TabNet, dan TabR	Model TabR efektif meningkatkan kinerja klasifikasi data tabular melalui mekanisme retrieval-augmented yang memanfaatkan konteks antar-sampel. Evaluasi

			pada dataset *benchmark* OpenML menunjukkan bahwa TabR unggul dibandingkan XGBoost dan TabNet pada beberapa skenario, dengan nilai AUC hingga 0,98 dan akurasi sekitar 0,93 pada dataset *electricity*, sehingga sesuai untuk klasifikasi data tabular dengan kompleksitas fitur yang beragam.

2.2 Dasar Teori

2.2.1 Ekspresi Wajah

Ekspresi wajah merupakan salah satu saluran komunikasi nonverbal utama yang digunakan manusia untuk menyampaikan kondisi emosional. Analisis ekspresi wajah menjadi topik penting dalam berbagai penelitian karena mampu merepresentasikan keadaan psikologis seseorang secara langsung (Zhao dkk., 2023). Umumnya, ekspresi wajah muncul secara tidak disengaja sebagai respons terhadap perasaan atau emosi yang dirasakan oleh individu (Dawel dkk., 2025).

Ekspresi wajah dapat dikenali melalui perubahan halus pada satu atau beberapa fitur wajah tertentu. Perubahan ini umumnya terjadi pada area seperti alis, kelopak mata, dan mulut, yang berperan penting dalam menyampaikan informasi emosional (Kim dkk., 2022). Keberadaan variasi perubahan pada fitur-fitur wajah tersebut menunjukkan bahwa ekspresi wajah tidak muncul dalam satu bentuk yang seragam, melainkan memiliki beragam pola yang dapat dibedakan berdasarkan karakteristik kemunculannya.



Gambar 2.1 Ekspresi Wajah

Berdasarkan karakteristik kemunculannya, ekspresi wajah dapat dibedakan menjadi ekspresi makro dan ekspresi mikro. Ekspresi makro merupakan bentuk ekspresi wajah yang mudah diamati dan dibedakan karena melibatkan perubahan pada hampir seluruh area wajah**.** Berbeda dari ekspresi makro, ekspresi mikro merupakan gerakan otot wajah yang terjadi secara tidak disengaja dengan durasi yang sangat singkat dan intensitas gerakan yang halus, berlangsung sekitar 0.04 hingga 0.2 detik, serta muncul pada beberapa bagian wajah sebagai indikasi adanya emosi yang disembunyikan oleh individu (Choirina dkk., 2022).

2.2.2 Ekspresi Mikro (*Micro Expression*)

Ekspresi mikro (*micro-expression*) merupakan ekspresi wajah yang muncul secara tidak disengaja, berdurasi sangat singkat, dan berintensitas rendah. Ekspresi ini terjadi ketika individu berusaha menyembunyikan atau menekan emosi yang sebenarnya, sehingga gerakan wajah yang muncul bersifat spontan dan sulit dikendalikan. Berbeda dengan ekspresi makro yang dapat dimanipulasi secara sadar, ekspresi mikro mampu mengungkap emosi autentik yang tersembunyi melalui perubahan otot wajah yang sangat halus dan berlangsung dalam waktu singkat (Ben dkk., 2021).



Gambar 2.2 *Micro-expressions*

Secara empiris, ekspresi mikro tidak hanya dibedakan oleh durasinya yang singkat, tetapi juga oleh intensitas aktivasi otot wajah yang

sangat rendah dan bersifat lokal. Intensitas pergerakan otot pada ekspresi mikro terbukti secara signifikan lebih kecil dibandingkan ekspresi makro, sehingga ekspresi yang muncul sering kali tidak membentuk pola wajah yang utuh dan sulit dikenali secara visual (Lu dkk., 2022). Selain itu, ekspresi mikro bersifat tidak disengaja dan muncul dalam konteks interaksi antara sistem motorik emosional dan sistem kontrol volunter wajah, yang menyebabkan pergerakan otot tidak selalu terorganisasi secara penuh seperti pada ekspresi sadar (Dong dkk., 2022). Dengan demikian, ekspresi mikro lebih tepat dipahami sebagai indikator kebocoran emosi yang kuat.

2.2.3 Gangguan Kecemasan (*Anxiety Disorder*)

Menurut Darajat dalam (Nurshabrina dkk., 2024), kecemasan dipahami sebagai perasaan antisipatif terhadap kemungkinan terjadinya situasi yang menakutkan, yang mendorong kesiapan individu untuk bertindak, namun pada kenyataannya ancaman tersebut tidak benar-benar terjadi dan tidak berkaitan dengan objek atau kondisi tertentu yang perlu dihindari. Secara psikologis, kondisi ini berbeda dari fear, karena fear muncul sebagai respons terhadap ancaman yang nyata dan spesifik serta memicu reaksi cepat seperti *fight or flight*, sedangkan *anxiety* berkaitan dengan ancaman yang tidak terdefinisi secara jelas dan menghasilkan kewaspadaan yang bersifat berkelanjutan (Watson dkk., 2022).

Kecemasan menjadi kondisi yang bersifat abnormal ketika intensitas dan durasinya tidak sebanding dengan ancaman yang dihadapi atau muncul tanpa sebab yang jelas, sehingga tidak lagi dapat dipahami sebagai respons adaptif terhadap lingkungan. Pada kondisi tersebut, kecemasan dapat berkembang menjadi gangguan psikologis yang mengganggu fungsi sosial, pekerjaan, serta aktivitas sehari-hari individu (Oktamarin dkk., 2022). Kondisi kecemasan yang bersifat abnormal tersebut tercermin pada tingginya prevalensi gangguan kecemasan di Indonesia menunjukkan bahwa kecemasan abnormal merupakan masalah kesehatan mental yang serius, dengan angka 9,8% pada remaja dan dewasa pada Data Riset Kesehatan Dasar tahun 2018 yang meningkat menjadi 26,7% berdasarkan

survei I-NAMHS 2022, terutama pada kelompok remaja dan pelajar (Dewi dkk., 2025).

Dalam interaksi sosial, kecemasan yang berlangsung terus-menerus tidak selalu diekspresikan secara jelas melalui ekspresi wajah yang mudah dikenali. Individu dengan *anxiety* cenderung melakukan regulasi emosi dengan menahan ekspresi negatif guna menjaga citra diri dan menyesuaikan diri dengan lingkungan sosial, sehingga tanda-tanda visual kecemasan sering kali tidak tampak secara eksplisit (Lei dkk., 2024). Sebagai konsekuensinya, respons emosional yang berkaitan dengan kecemasan lebih sering muncul dalam bentuk aktivasi otot wajah yang bersifat tidak disengaja, berintensitas sangat rendah, dan berdurasi singkat. Pola kemunculan tersebut sejalan dengan karakteristik *micro-expressions*, yaitu ekspresi wajah yang timbul ketika individu berupaya menyembunyikan emosi yang sesungguhnya, namun tetap menunjukkan kebocoran emosi secara spontan (Zhao dkk., 2023). Dalam kerangka *micro-expressions*, perubahan tersebut tampak pada area berikut:

1. Area mata, khususnya perubahan halus di sekitar bagian bawah mata yang mencerminkan peningkatan kewaspadaan.
2. Area sudut bibir (*lip corner*), yang menunjukkan ketegangan ringan sebagai respons terhadap ketidaknyamanan emosional.

Perubahan pada area-area tersebut bersifat sementara dan sulit dikenali secara kasat mata, sehingga lebih relevan dianalisis dalam kerangka *micro-expressions* dan pendekatan visual yang sensitif terhadap perubahan kecil pada fitur wajah (Sharma dkk., 2024).

Kecemasan tidak hanya muncul sebagai respons terhadap ancaman yang akan dihadapi, tetapi juga dapat berlanjut setelah situasi pemicu berakhir. Dalam konteks akademik, dinamika kecemasan ujian mencakup beberapa fase, yaitu sebelum ujian, periode setelah ujian hingga pengumuman hasil, serta fase pasca pengumuman nilai. Penelitian menunjukkan bahwa individu tidak berhenti memproses pengalaman ujian ketika ujian selesai, melainkan masih terlibat dalam pemikiran dan evaluasi berulang terhadap performa yang telah dilakukan. Bahkan, *post-event*

processing ditemukan muncul secara bermakna setelah situasi ujian dan berhubungan dengan tingkat kecemasan yang dialami individu (Möcklinghoff dkk., 2024). Temuan ini menunjukkan bahwa gangguan kecemasan melibatkan proses kognitif yang dapat berlangsung baik sebelum maupun setelah stimulus pemicu kecemasan berakhir.

2.2.4 Pengolahan Citra (*Image Processing*)

Pengolahan citra merupakan bidang komputasi yang berfokus pada pemrosesan dan analisis citra digital untuk memperoleh informasi visual yang bermakna. Citra digital dipahami sebagai representasi dua dimensi dari objek visual yang tersusun atas kumpulan piksel dengan nilai intensitas tertentu, sehingga dapat diolah secara komputasional. Dalam praktiknya, pengolahan citra mencakup berbagai teknik seperti peningkatan kualitas citra, restorasi, segmentasi, ekstraksi fitur, dan klasifikasi guna meningkatkan interpretabilitas citra oleh manusia maupun sistem komputer (Archana dkk., 2024). Dalam perkembangannya, pengolahan citra juga menjadi bagian dari kecerdasan buatan karena memanfaatkan citra digital sebagai masukan utama untuk proses analisis dan pengambilan keputusan berbasis komputasi.

Berdasarkan jenis datanya, pengolahan citra dibedakan menjadi pengolahan citra statis dan pengolahan citra bergerak. Citra statis merepresentasikan objek visual pada satu waktu tertentu, sedangkan citra bergerak tersusun atas rangkaian citra digital (*frames*) yang diperoleh secara berurutan dari aliran video. Setiap *frame* pada citra bergerak diperlakukan sebagai citra digital yang dapat dianalisis secara individual maupun dengan membandingkannya terhadap *frame* lain yang berurutan dalam domain waktu, sehingga memungkinkan identifikasi perubahan visual yang terjadi antar *frame* (Sinulingga dkk., 2023).

2.2.5 Deteksi Wajah

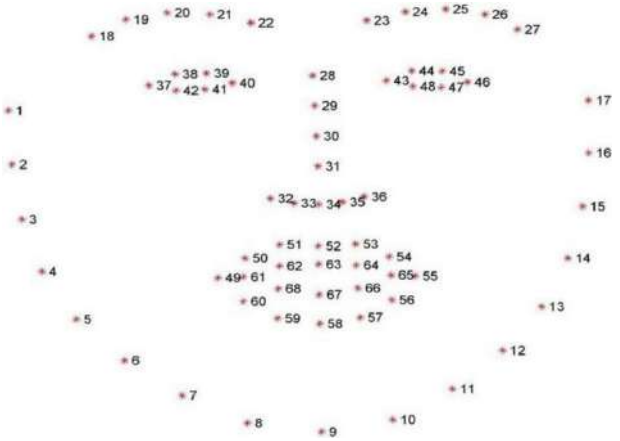
Deteksi wajah merupakan tahap awal dalam pemrosesan citra wajah yang bertujuan untuk mengidentifikasi keberadaan wajah manusia dan memisahkan area wajah dari latar belakang pada citra atau video. Tahap ini penting karena memastikan bahwa analisis selanjutnya hanya difokuskan

pada wilayah wajah yang relevan sebelum dilakukan pemrosesan lanjutan (Li dkk., 2022). Dalam konteks analisis *micro-expression*, hasil deteksi wajah digunakan sebagai *facial region* yang menjadi masukan untuk proses lanjutan seperti pelacakan titik fitur, ekstraksi pergerakan otot wajah, serta analisis perubahan visual yang bersifat sangat halus dan singkat (Choirina dkk., 2022).

Seiring perkembangan teknik komputasi, deteksi wajah tidak hanya diterapkan pada citra statis, tetapi juga pada citra bergerak atau video yang tersusun atas rangkaian *frame*. Dalam konteks ini, wajah diekstraksi dari urutan citra wajah sebagai dasar pemrosesan lanjutan, sehingga memungkinkan analisis wajah dilakukan secara konsisten pada setiap bagian dari rangkaian citra tersebut untuk mendukung analisis ekspresi wajah yang bersifat dinamis dan berlangsung singkat (Liu dkk., 2022).

2.2.6 Dlib

Dlib merupakan *library open-source* yang menyediakan berbagai fungsi dan algoritma untuk pengolahan citra dan visi komputer, khususnya pada pemrosesan wajah. Dlib digunakan untuk mengekstraksi dan menganalisis karakteristik wajah dari citra atau video, seperti deteksi wajah dan pelokalan titik-titik *landmark* wajah, sehingga mendukung proses pemrosesan lanjutan dalam analisis wajah (Sejati dkk., 2021). Melalui pendekatan *facial landmark*, Dlib memungkinkan identifikasi komponen wajah seperti mata, alis, dan mulut sebagai bagian dari tahap pra-pemrosesan sebelum dilakukan analisis lanjutan (Nur Cahyo dkk., 2023). Representasi *facial landmark* pada Dlib ditunjukkan pada gambar berikut:



Gambar 2.3 *Facial Landmark* Dlib

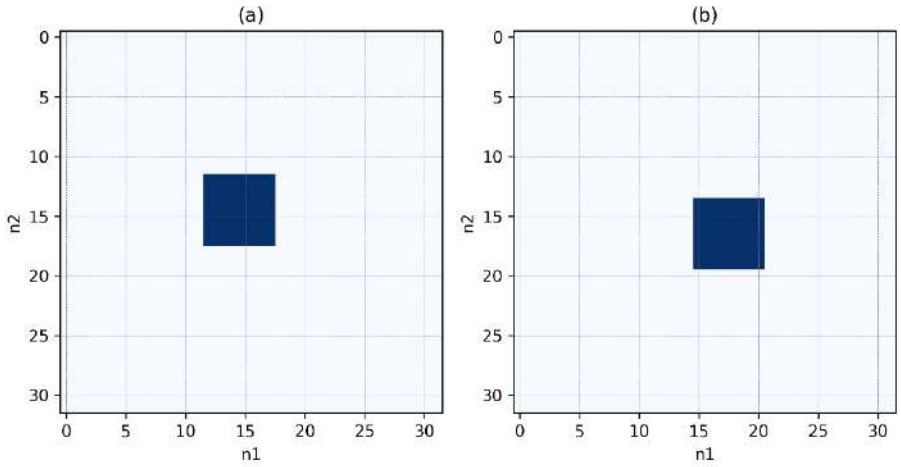
Gambar tersebut menunjukkan representasi *facial landmark* yang digunakan oleh Dlib, di mana setiap titik merepresentasikan posisi geometris tertentu pada wajah. Titik-titik *landmark* ini digunakan untuk memetakan struktur wajah, seperti area alis, mata, hidung, dan mulut, sehingga pergerakan atau perubahan pada bagian wajah dapat dianalisis secara lebih terperinci.

2.2.7 *Phase Only Correlation with All Block Search* (POC-ABS)

Phase Only Correlation with All Block Search (POC-ABS) merupakan metode estimasi pergerakan berbasis *block matching* yang dirancang untuk mendeteksi pergerakan wajah yang sangat halus dan berdurasi singkat pada *micro-expression*. Metode ini bekerja dengan membandingkan setiap blok pada dua *frame* yang berurutan untuk menentukan ada atau tidaknya pergerakan translasi pada blok yang sama. Jika dua blok identik, maka tidak dihasilkan vektor gerak, sedangkan perbedaan antar blok akan menghasilkan vektor gerak yang merepresentasikan adanya pergerakan halus pada area wajah tertentu. Vektor gerak tersebut selanjutnya digunakan sebagai fitur pergerakan untuk merepresentasikan kebocoran ekspresi yang muncul secara spontan dan berintensitas rendah (Rosiani dkk., 2020). Pada penelitian ini, POC diimplementasikan sebagai metode ekstraksi fitur berbasis gerak yang bertujuan untuk merepresentasikan pergerakan pada berbagai area wajah melalui informasi perubahan pada tingkat piksel.

Dalam implementasinya, POC menggunakan *Fast Fourier Transform* (FFT) untuk mengubah gambar menjadi representasi dalam domain frekuensi. Data yang diproses oleh FFT berupa intensitas piksel dari citra atau blok citra yang dianalisis. Transformasi ini mengubah representasi spasial ke domain frekuensi sehingga informasi fase dapat dimanfaatkan untuk menentukan pergeseran antar blok gambar secara efisien berdasarkan karakteristik frekuensi (Rosiani dkk., 2020). Dengan cara ini, perhitungan fase dapat dilakukan secara efisien untuk menentukan pergeseran antara blok gambar berdasarkan informasi frekuensi.

Berdasarkan mekanisme tersebut, proses estimasi pergerakan pada POC-ABS dilakukan dengan membagi citra ke dalam blok-blok kecil yang dianalisis secara lokal. Pembagian citra ke dalam blok-blok kecil memungkinkan analisis pergerakan dilakukan secara lokal pada area wajah tertentu. Dengan pendekatan ini, dua *frame* yang berurutan, yaitu *n1* dan *n2*, dibandingkan pada blok yang bersesuaian untuk mengamati adanya pergeseran atau perubahan pergerakan, sebagaimana diilustrasikan pada Gambar 2.2.



Gambar 2.4 Contoh dua *frame* untuk n1 dan n2

Sumber:

POC-ABS digunakan untuk mengestimasi pergerakan antara dua *frame*, yaitu *frame* referensi dan *frame* pada waktu berikutnya. Misalkan terdapat dua *frame* berukuran $N_1 \times N_2$ yang dinyatakan sebagai $f(n_1, n_2)$dan $g(n_1, n_2)$, sebagaimana ditunjukkan pada Gambar 2.2.

Untuk mempermudah formulasi, indeks koordinat diasumsikan berada pada rentang $n_1 = -M_1, \dots, M_1$dan $n_2 = -M_2, \dots, M_2$, dengan $N_1 = 2M_1 + 1$dan $N_2 = 2M_2 + 1$. Transformasi Fourier Diskrit dari kedua frame tersebut selanjutnya dinyatakan dalam bentuk persamaan sebagai berikut.

$$F = (k1, k2) = \sum_{n_1, n_2} f(n_1, n_2) W_{N_1}^{k_1 n_1} W_{N_2}^{k_2 n_2}$$
$$= A_f(k_1 k_2) e^{j\theta_F\left(k_{1k_2}\right)}$$

Keterangan**:**

- $F(k_1, k_2)$ merupakan hasil Transformasi Fourier dua dimensi dari frame $f(n_1, n_2)$ yang merepresentasikan citra pada domain frekuensi.
- $W_{N_1} = e^{-j\frac{2\pi}{N_1}}$ dan $W_{N_2} = e^{-j\frac{2\pi}{N_2}}$ adalah konstanta kompleks yang digunakan dalam perhitungan Transformasi Fourier Diskrit (DFT) untuk masing-masing dimensi citra.
- $k_1$dan $k_2$menyatakan indeks frekuensi pada domain Fourier yang merepresentasikan komponen frekuensi horizontal dan vertikal.
- Spektrum Fourier $F(k_1, k_2)$ dapat dinyatakan dalam bentuk polar sebagai $F(k_1, k_2) = A_F(k_1, k_2)\, e^{j\theta_F(k_1, k_2)}$, di mana $A_F(k_1, k_2)$ merepresentasikan amplitudo spektrum dan $\theta_F(k_1, k_2)$ menyatakan informasi fase.

$$G = (k1, k2) = \sum_{n_1, n_2} f(n_1, n_2) W_{N_1}^{k_1 n_1} W_{N_2}^{k_2 n_2}$$
$$= A_g(k_1 k_2) e^{j\theta_F\left(k_{1k_2}\right)}$$

Keterangan:

- $G(k_1, k_2)$ merupakan hasil Transformasi Fourier dua dimensi dari frame $g(n_1, n_2)$ yang merepresentasikan citra pada domain frekuensi.
- $W_{N_1} = e^{-j\frac{2\pi}{N_1}}$dan $W_{N_2} = e^{-j\frac{2\pi}{N_2}}$ merupakan konstanta kompleks yang digunakan dalam perhitungan Transformasi Fourier Diskrit (DFT) pada masing-masing dimensi citra.

- Spektrum Fourier $G(k_1, k_2)$ dapat dinyatakan dalam bentuk polar sebagai $G(k_1, k_2) = A_G(k_1, k_2)\, e^{j\theta_G(k_1,k_2)}$, di mana $A_G(k_1, k_2)$ menyatakan amplitudo spektrum dan $\theta_G(k_1, k_2)$ merepresentasikan informasi fase.

  Cross spectrum $\hat{R}(k_1, k_2)$ antara spektrum Fourier $F(k_1, k_2)$ dan $G(k_1, k_2)$ didefinisikan sebagai hasil normalisasi perkalian antara $F(k_1, k_2)$ dan konjugat kompleks dari $G(k_1, k_2)$. Normalisasi ini bertujuan untuk menghilangkan pengaruh amplitudo sehingga hanya informasi fase yang dipertahankan. Dengan demikian, cross spectrum dapat dinyatakan sebagai fungsi yang merepresentasikan selisih fase antara kedua spektrum *Fourier*.

$$R(k_1 k_2) = \frac{F(k_1, k_2)G(k_1, k_2)}{|F(k_1, k_2)||G(k_1, k_2)|}$$

$$= e^{j(\theta_F(k_1,k_2) - \theta_G(k_1,k_2))}$$

  Keterangan:

  - $G^*(k_1, k_2)$ menyatakan konjugat kompleks dari spektrum Fourier $G(k_1, k_2)$.
  - $\hat{R}(k_1, k_2)$ merupakan *cross-power spectrum* yang hanya memuat informasi perbedaan fase antara dua citra pada domain frekuensi.
  - $\theta(k_1, k_2)$ menyatakan selisih fase antara dua spektrum Fourier, yang didefinisikan sebagai $\theta_F(k_1, k_2) - \theta_G(k_1, k_2)$.

  Dengan menggunakan konjugat kompleks dari $G(k_1, k_2)$, *cross-power spectrum* menekankan perbedaan fase antara dua frame tanpa melibatkan informasi amplitudo. Selisih fase tersebut merepresentasikan pergeseran translasi yang terjadi antarframe. Selanjutnya, fungsi Phase Only Correlation (POC) $\hat{r}(n_1, n_2)$diperoleh melalui Transformasi Fourier Diskrit dua dimensi terbalik (*inverse DFT*) dari $\hat{R}(k_1, k_2)$, yang secara matematis dirumuskan sebagai berikut.

$$\hat{r}(n_1, n_2) = \frac{1}{N_1 N_2} \sum_{k_1,k_2} R(k_1, k_2) W_{N_1}^{-k_1 n_1} W_{N_2}^{-k_2 n_2}$$

Keterangan:

- $r(n_1, n_2)$ merupakan fungsi korelasi *Phase Only Correlation* (POC) pada domain spasial yang diperoleh dari transformasi balik spektrum fase.
- Nilai maksimum dari $r(n_1, n_2)$ merepresentasikan keberadaan puncak korelasi, di mana tinggi puncak menunjukkan tingkat kemiripan fase antara dua frame, sedangkan posisi puncak menunjukkan estimasi pergeseran translasi antarframe.

Dalam kondisi dua *frame* identik, dengan $f(n_1, n_2) = g(n_1, n_2)$, fungsi POC dapat dirumuskan sebagai berikut.

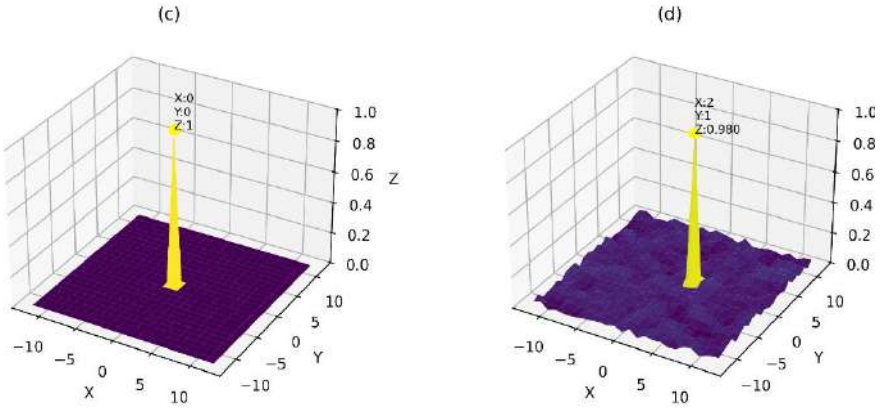
$$\hat{r}(n_1, n_2) = \frac{1}{N_1 N_2} \sum_{k_1,k_2} W_{N_1}^{-k_1 n_1} W_{N_2}^{-k_2 n_2} = \delta(n_1, n_2)$$

$$\delta(n_1, n_2) = \begin{cases} 1 & Jika\ n_1 = n_1 = 0 \\ 0 & Jika\ selain\ itu \end{cases}$$

Keterangan:

- $\delta(n_1, n_2)$ merupakan fungsi delta Kronecker dua dimensi yang berperan sebagai indikator kesesuaian sempurna, di mana nilainya bernilai satu pada kondisi tertentu dan nol pada kondisi lainnya.
- Nilai maksimum dari $r(n_1, n_2)$ bernilai satu hanya ketika pergeseran translasi bernilai nol, yang menunjukkan bahwa kedua frame tidak mengalami pergeseran dan bersifat identik secara sempurna.

Jika dua blok gambar identik, nilai POC akan sama dengan 1 dan menghasilkan puncak tajam yang sempurna. Sebaliknya, jika tidak identik, nilai POC akan turun secara signifikan.



Gambar 2.5 Proses POC deteksi pergerakan dari gambar contoh 2.2

Sumber: (Rosiani dkk., 2020)

Hasil perbandingan pada Gambar 2.3 menghasilkan dua fitur utama, yaitu koordinat Xdan Y, yang merepresentasikan pergeseran piksel dari titik pusat $(0, 0)$ menuju posisi baru (X, Y) setelah terjadinya pergeseran antarframe. Nilai Xdan Ymenunjukkan arah serta jarak perpindahan blok dari frame referensi ke frame berikutnya.

Berdasarkan kedua nilai tersebut, selanjutnya dapat diturunkan dua fitur tambahan, yaitu sudut pergeseran (*theta*) dan besar pergeseran (*magnitude*). Sudut *theta* merepresentasikan arah vektor pergeseran yang dihitung menggunakan hubungan trigonometri antara komponen Xdan Y, sedangkan *magnitude* menyatakan panjang vektor pergeseran yang menggambarkan besar perubahan posisi blok. Persamaan untuk menghitung nilai *theta* dinyatakan sebagai berikut:

$$\theta_{rad} = arctan\frac{y}{x}$$

Keterangan:

- $x$menyatakan komponen pergeseran horizontal yang menunjukkan arah perpindahan ke kanan atau ke kiri.
- $y$menyatakan komponen pergeseran vertikal yang menunjukkan arah perpindahan ke atas atau ke bawah.
- Sudut θmerepresentasikan arah vektor pergeseran (x, y)terhadap sumbu X.

- Nilai sudut tersebut dihitung dalam satuan radian menggunakan fungsi *arc-tangent*, yang menunjukkan arah terjadinya pergerakan blok, seperti ke kanan, ke atas, ke kiri, atau kombinasi arah lainnya.

$$\theta_{deg} = \theta_{rad} \cdot \frac{180}{\pi}$$

Keterangan:

- Nilai θ_{rad} dinyatakan dalam satuan radian, sehingga perlu dikonversi ke satuan derajat $(^\circ)$ agar arah pergerakan lebih mudah dipahami dan diinterpretasikan secara intuitif.

$$\theta = \theta_{deg} + \left(360 \cdot (y < 0)\right)$$

Keterangan:

- Kondisi $y < 0$ menunjukkan bahwa arah vektor pergeseran berada pada kuadran tertentu, sehingga diperlukan penyesuaian sudut dengan menambahkan 360° agar representasi sudut berada pada rentang yang konsisten.
- Operasi logika $(y < 0)$ menghasilkan nilai 1 ketika kondisi terpenuhi dan bernilai 0 ketika $y \geq 0$, sehingga penambahan sudut dilakukan secara kondisional.

Sedangkan untuk nilai Magnitude dapat dihitung dengan persamaan berikut:

$$m = \sqrt{x^2 + y^2}$$

Keterangan:

- Nilai *magnitude* $m$menyatakan panjang vektor pergerakan yang dihitung dari komponen horizontal $x$dan komponen vertikal $y$menggunakan prinsip Teorema Pythagoras.
- Nilai *magnitude* yang besar menunjukkan adanya pergerakan dengan intensitas tinggi, sedangkan nilai *magnitude* yang kecil merepresentasikan pergerakan mikro atau perubahan yang sangat halus.

Dengan memanfaatkan fitur X, Y, sudut pergeseran (*theta*), dan *magnitude*, data hasil ekstraksi dapat disusun menjadi sebuah dataset yang digunakan pada tahap selanjutnya, yaitu proses klasifikasi. Melalui POC,

informasi penting terkait pergerakan mikro pada wajah dapat diekstraksi secara terstruktur untuk dianalisis lebih lanjut dalam pengenalan *micro-expression.* Proses ekstraksi fitur ini dilakukan secara berulang pada setiap pasangan *frame*, sehingga dihasilkan representasi fitur yang menggambarkan arah dan besar vektor pergerakan sepanjang seluruh rangkaian citra yang dianalisis.

Berikut dijelaskan tahapan metode *Phase Only Correlation with All Block Search* (POC-ABS) secara lebih terperinci.

1. Tahapan Perhitungan POC-ABS per Blok
    a. Pemotongan citra menjadi blok

        Citra dibagi menjadi beberapa blok berukuran tetap. Sebagai contoh, untuk citra berukuran 70 × 35 piksel dengan ukuran blok (*block size*) sebesar 7, jumlah blok yang dihasilkan adalah (70/7) × (35/7) = 10 × 5, sehingga diperoleh total 50 blok.

        Sebagai ilustrasi, blok ke-22 memiliki area citra pada koordinat x = 14 hingga 21 dan y = 14 hingga 21. Blok yang bersesuaian dari frame referensi dan frame berikutnya dipotong untuk kemudian dibandingkan.

    b. Penerapan window Hanning

        Untuk mengurangi efek tepi (*edge effect*) pada setiap blok, diterapkan fungsi window Hanning dua dimensi yang dirumuskan sebagai berikut:

$$w(x, y) = hanning(x) \cdot hanning(y)^T$$

        Jika ukuran blok adalah 7, maka window Hanning yang dihasilkan berbentuk matriks berukuran 7 × 7 dan diaplikasikan pada setiap blok sebelum transformasi Fourier.

    c. Transformasi Fourier

        Blok citra hasil pemotongan kemudian ditransformasikan ke domain frekuensi menggunakan Transformasi Fourier Diskrit dua dimensi (FFT2):

$$F_1(u, v) = FFT_2(block_{ref} \cdot w)$$

$$F_2(u,v) = FFT_2(block_{curr} \cdot w)$$

di mana $block_{ref}$ dan $block_{curr}$ masing-masing merupakan blok dari frame referensi dan frame saat ini.

d. Hitung Korelasi Fase

Hasil korelasi fase pada domain spasial diperoleh melalui transformasi Fourier balik:

$$r(x,y) = | IFFT_2(R) |$$

Matriks $r(x,y)$berukuran 7 × 7 merepresentasikan nilai korelasi spasial antarblok.

e. Deteksi Titik Puncak Korelasi (*Peak Detection*)

Titik puncak korelasi ditentukan dengan mencari nilai maksimum pada matriks $r(x,y)$. Koordinat puncak dihitung sebagai berikut:

$$peak = np.unravel_index(np.argmax(r), r.shape)$$
$$dy = peak[0] - center$$
$$dx = peak[1] - center$$

Sebagai contoh, jika puncak korelasi berada pada koordinat (5, 3) dan pusat blok berada pada (3, 3), maka diperoleh nilai dx = 0 dan dy = +2, yang menunjukkan bahwa blok mengalami pergeseran dua piksel ke arah bawah.

2. Vector Gerak (*Motion Vektor*)

Berdasarkan nilai *dx* dan *dy* pada setiap blok, vektor gerak dihitung menggunakan dua parameter utama, yaitu *magnitude* dan sudut pergeseran (*theta*).

- Magnitude dihitung sebagai:

$$m = \sqrt{dx^2 + dy^2}$$

- Sudut pergeseran (theta) dihitung sebagai:

$$\theta = \tan^{-1}\left(\frac{dy}{dx}\right)$$

Sebagai contoh, untuk sebuah blok dengan dx = 1 dan dy = −2, diperoleh nilai magnitude sebesar $\sqrt{5} \approx 2{,}24$dan sudut $\theta \approx -63{,}43°$.

3. Contoh fitur hasil ekstraksi

Setiap blok menghasilkan fitur berupa posisi dan vektor gerak. Contoh hasil ekstraksi fitur ditunjukkan pada Tabel berikut:

Tabel 2.2 Contoh hasil ekstraksi fitur

Blok	X	Y	Magnitude	Theta
10	10	10	2.00	0° (kanan)
22	17	17	2.24	-63° (kanan bawah)
41	10	31	2.00	90° (bawah)
46	45	31	1.41	-45° (kanan bawah)
50	63	31	2.00	180° (kiri)

Blok dengan vektor panjang dan arah yang jelas menunjukkan adanya pergerakan nyata, sedangkan blok dengan dx = dy = 0 menandakan tidak adanya pergerakan.

4. Visualisasi vektor gerak

Visualisasi pergerakan dilakukan menggunakan panah (*quiver*), dengan ketentuan sebagai berikut:

- Xdan Ymerepresentasikan posisi tengah blok.
- Udan Vmerepresentasikan komponen arah vektor gerak (dx, dy).
- Panah hanya tampil pada blok yang memiliki $dx \neq 0$ atau $dy \neq 0$.

2.2.8 Data Tabular

Data tabular merupakan representasi data yang disusun dalam struktur baris dan kolom, di mana setiap baris merepresentasikan satu objek atau sampel pengamatan, sedangkan setiap kolom merepresentasikan fitur yang menggambarkan karakteristik objek tersebut. Dalam format ini, setiap sampel dinyatakan sebagai vektor fitur numerik yang terorganisasi secara sistematis sehingga memudahkan proses analisis dan pemodelan, sejalan dengan definisi bahwa data tabular terdiri atas baris yang merepresentasikan objek dan kolom yang merepresentasikan fitur (Arik dkk., 2021). Representasi tabular banyak digunakan dalam berbagai permasalahan

klasifikasi dan regresi karena mampu menyajikan informasi numerik secara terstruktur serta kompatibel dengan beragam algoritma pembelajaran mesin, dan bahkan merupakan tipe data yang paling umum dijumpai dalam aplikasi pembelajaran mesin di dunia nyata (Gorishniy dkk., 2024).

Dalam konteks analisis *micro-expression*, data tabular digunakan sebagai bentuk representasi fitur hasil ekstraksi pergerakan wajah yang bersifat numerik. Setiap sampel ekspresi wajah dapat direpresentasikan sebagai satu baris data yang memuat kumpulan fitur pergerakan, sedangkan setiap fitur merepresentasikan karakteristik pergerakan tertentu pada area wajah. Representasi ini memungkinkan informasi pergerakan mikro yang sangat halus dan berdurasi singkat untuk dimodelkan secara eksplisit tanpa bergantung pada struktur spasial citra atau urutan temporal video. Dengan demikian, data tabular menyediakan kerangka representasi yang dapat digunakan untuk memodelkan hubungan antar-fitur dan antar-sampel secara sistematis, khususnya pada pendekatan klasifikasi berbasis *deep learning* tabular.

2.2.9 *Facebook AI Similarity Search* (FAISS)

Facebook AI Similarity Search (FAISS) merupakan pustaka *open-source* yang dikembangkan oleh Facebook AI *Research* untuk melakukan pencarian kemiripan (*similarity search*) pada vektor berdimensi tinggi secara efisien. FAISS bekerja dengan membangun indeks yang dapat menyimpan hingga miliaran vektor *embedding* dan digunakan untuk mengambil sejumlah *k* vektor yang paling mirip terhadap suatu vektor *query*. Proses pencarian kemiripan pada FAISS umumnya dilakukan menggunakan metrik jarak seperti *Euclidean distance* (L2) atau *cosine similarity*, sehingga memungkinkan penerapan *retrieval* berbasis *embedding* pada data berskala besar dengan waktu pencarian yang sangat cepat (Schwarz dkk., 2022).

Dalam konteks *embedding-based retrieval*, pencarian informasi dilakukan dengan merepresentasikan data dan *query* dalam bentuk *embedding* numerik, kemudian mengubah permasalahan *retrieval* menjadi pencarian tetangga terdekat pada ruang *embedding*. Pendekatan ini

umumnya digunakan pada lapisan *retrieval* awal yang berfungsi mengambil sejumlah kandidat relevan secara efisien sebelum tahap pemeringkatan lanjutan. Dalam sistem *retrieval* modern, FAISS dimanfaatkan sebagai pustaka pendukung untuk menjalankan proses pencarian kemiripan berbasis *nearest neighbor* secara efisien, tanpa berperan sebagai model pembelajaran itu sendiri, melainkan sebagai infrastruktur yang mendukung mekanisme *retrieval* pada sistem berbasis *embedding* (Huang dkk., 2020).

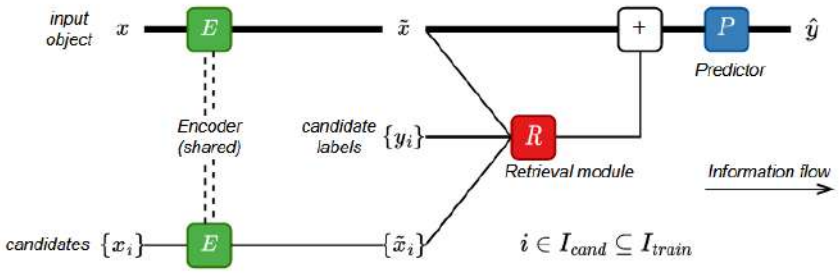
Secara teknis, FAISS mengimplementasikan *Approximate Nearest Neighbor (ANN) search* dengan membangun indeks vektor berbasis *vector quantization* untuk menekan kompleksitas pencarian. Salah satu struktur indeks yang umum digunakan adalah *Inverted File Index (IVF)*, di mana ruang embedding dipartisi menggunakan *k-means clustering* ke dalam sejumlah *coarse clusters*. Pada saat *query*, pencarian hanya dilakukan pada *cluster* terdekat (*nprobe*), sehingga menghindari komputasi jarak terhadap seluruh vektor. Untuk efisiensi memori dan kecepatan, FAISS mengombinasikan IVF dengan *Product Quantization (PQ)* yang mengompresi vektor menjadi representasi diskret dan memungkinkan perhitungan jarak secara aproksimasi menggunakan *lookup table*. Variasi lanjutan seperti *Optimized Product Quantization (OPQ)* digunakan untuk meningkatkan akurasi dengan melakukan rotasi ruang *embedding* sebelum kuantisasi. Melalui pengaturan parameter seperti jumlah *cluster* (*nlist*), jumlah *cluster* yang dipindai (*nprobe*), dan ukuran kode kuantisasi, FAISS menyediakan kontrol langsung terhadap *trade-off* antara *recall*, *latency*, dan *memory usage* pada sistem retrieval berskala besar (Huang dkk., 2020).

2.2.10 *Tabular Retrieval Network* (TabR)

Tabular Retrieval Network (TabR) merupakan model *deep learning* yang dirancang khusus untuk permasalahan klasifikasi dan regresi pada data tabular dengan mengintegrasikan mekanisme *retrieval* ke dalam jaringan saraf *feed-forward*. TabR dikembangkan untuk mengatasi keterbatasan model *deep learning* tabular konvensional yang sering kali masih tertinggal performanya dibandingkan metode *gradient-boosted decision trees* (GBDT). Dengan memanfaatkan prinsip *retrieval-augmented learning*,

TabR memperkaya representasi suatu sampel dengan informasi dari sampel lain yang paling relevan dalam data latih, sehingga prediksi tidak hanya bergantung pada bobot model, tetapi juga pada konteks lokal antar-sampel (Gorishniy dkk., 2024).

Pendekatan *retrieval* pada TabR memungkinkan model menangkap hubungan lokal yang sulit direpresentasikan melalui transformasi global semata, terutama pada data tabular dengan ukuran kecil hingga menengah. Studi empiris menunjukkan bahwa TabR mencapai performa rata-rata terbaik di antara model *deep learning* tabular pada berbagai benchmark publik, serta pada sejumlah dataset mampu menyamai bahkan melampaui performa GBDT. Selain meningkatkan akurasi, mekanisme *retrieval* juga membantu TabR menghasilkan prediksi yang lebih adaptif terhadap distribusi data lokal, khususnya pada tugas klasifikasi (Gorishniy dkk., 2024; Pasaribu dkk., 2024).



Gambar 2.6 Arsitektur TabR

Sumber: (Gorishniy dkk., 2024)

Berdasarkan Gambar 2.4, arsitektur *Tabular Retrieval Network* (TabR) dikembangkan dari jaringan *feed-forward* yang dinyatakan sebagai

$$f(x) = P(E(x))$$

dengan menambahkan modul *retrieval* R setelah encoder dalam bentuk cabang *residual*. *Encoder* berfungsi memetakan sampel target x dan sampel kandidat $\{x_i\}$ ke dalam ruang representasi laten yang sama, sehingga diperoleh representasi

$$\tilde{x} = E(x) \text{ dan } \tilde{x}_i = E(x_i).$$

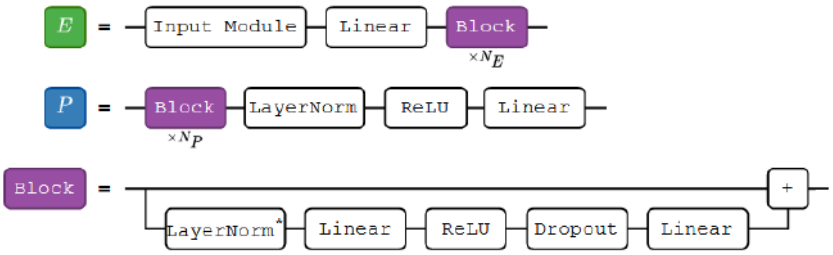
Selanjutnya, modul *retrieval* memanfaatkan kemiripan antar-sampel pada ruang laten, yang umumnya diukur menggunakan jarak, untuk mengambil informasi dari sampel kandidat yang paling relevan dan menggabungkannya dengan representasi laten sampel target. Representasi akhir dapat dinyatakan sebagai

$$z = \tilde{x} + R(\tilde{x}, \{\tilde{x}_i, y_i\}),$$

yang kemudian digunakan oleh *predictor* untuk menghasilkan prediksi

$$\hat{y} = P(z).$$

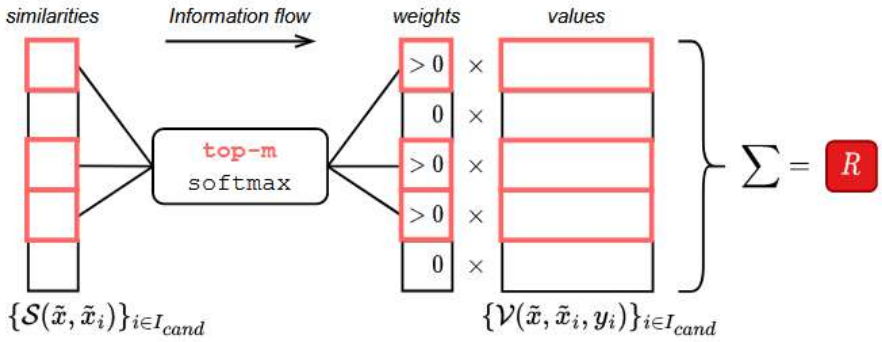
Dengan mekanisme ini, keputusan model tidak hanya bergantung pada bobot jaringan, tetapi juga mempertimbangkan konteks lokal antar-sampel.



Gambar 2.7 *Encoder* dan *Decoder*

Sumber: (Gorishniy dkk., 2024)

Berdasarkan Gambar 2.5, *encoder* E dan predictor P pada TabR dirancang sebagai jaringan *feed-forward* sederhana. *Encoder* memproses data tabular melalui *Input Module* untuk melakukan pemrosesan awal fitur, kemudian dilanjutkan dengan beberapa *block* pemrosesan guna menghasilkan representasi laten $\tilde{x}$ yang digunakan pada tahap retrieval dan prediksi. *Predictor* P selanjutnya memetakan representasi laten tersebut ke ruang keluaran melalui rangkaian *block* dan lapisan linear untuk menghasilkan prediksi akhir.



Gambar 2.8 Retreival Module

Sumber: (Gorishniy dkk., 2024)

Berdasarkan Gambar 2.6, modul *retrieval R* bekerja dengan memilih sejumlah m sampel kandidat yang paling mirip dengan sampel target pada ruang representasi laten. Nilai kemiripan antar-sampel dihitung menggunakan fungsi kemiripan

$$s_i = S(\tilde{x}, \tilde{x}_i),$$

kemudian dinormalisasi menggunakan fungsi *softmax* untuk memperoleh bobot kontribusi

$$w_i = \frac{\exp(s_i)}{\sum_{j \in I_{cand}} \exp(s_j)}.$$

Selanjutnya, informasi dari sampel kandidat diagregasi menggunakan bobot tersebut untuk menghasilkan keluaran modul *retrieval*

$$R = \sum_{i=1}^{m} w_i \cdot V(\tilde{x}, \tilde{x}_i, y_i),$$

yang digunakan untuk memperkaya representasi laten sampel target sebelum dilakukan prediksi akhir.

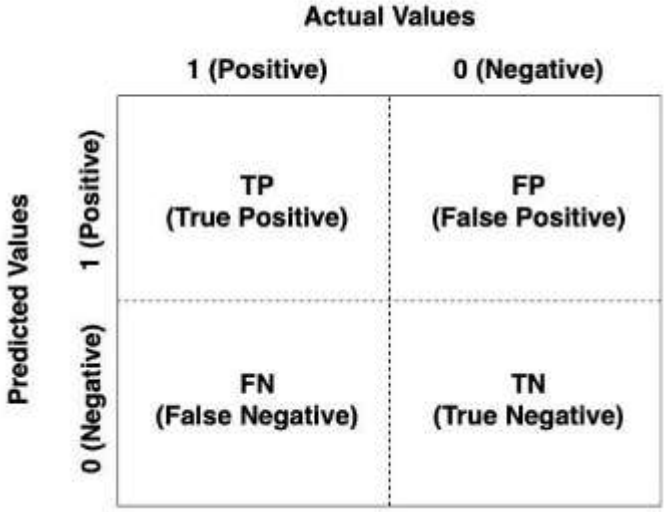
2.2.11 *Confussion Matrix*

Confusion matrix merupakan tabel kontingensi dua dimensi yang digunakan untuk mengevaluasi kinerja model klasifikasi dengan

membandingkan label aktual dan label prediksi. Struktur ini memungkinkan analisis kesalahan klasifikasi secara eksplisit melalui empat komponen utama, yaitu *true positive*, *false positive*, *true negative*, dan *false negative*. Dengan representasi baris dan kolom yang merepresentasikan kelas aktual dan kelas prediksi, confusion matrix memberikan gambaran langsung mengenai pola kesalahan model serta tingkat keberhasilan klasifikasi pada setiap kelas, sehingga menjadi dasar penting dalam evaluasi sistem klasifikasi, khususnya pada masalah biner maupun multikelas (Yang dkk., 2024).

Confusion matrix tidak hanya berfungsi sebagai alat visualisasi kesalahan klasifikasi, tetapi juga menjadi dasar perhitungan berbagai metrik evaluasi kinerja seperti *accuracy*, *precision*, *recall*, *sensitivity*, dan *specificity*. Metrik-metrik tersebut memungkinkan penilaian performa model secara lebih komprehensif, terutama pada kondisi data tidak seimbang, di mana akurasi saja dapat memberikan gambaran yang menyesatkan. Oleh karena itu, confusion matrix dianggap sebagai fondasi utama dalam evaluasi model pembelajaran mesin karena mampu menunjukkan secara rinci kekuatan dan kelemahan model pada masing-masing kelas (Sathyanarayanan, 2024).

Berdasarkan konsep tersebut, confusion matrix dapat direpresentasikan secara visual seperti pada Gambar 2.7, yang menunjukkan distribusi hasil klasifikasi antara kelas aktual dan kelas prediksi.



Gambar 2.9 Gambar *Confusion Matrix*

Dalam penelitian ini, *confusion matrix* digunakan untuk mengevaluasi kinerja model dalam mengklasifikasikan kondisi *anxiety* tinggi dan *anxiety* rendah. Kelas *anxiety tinggi* ditetapkan sebagai kelas positif, sedangkan kelas *anxiety rendah* sebagai kelas negatif. Dengan demikian, *true positive* (TP) adalah jumlah sampel anxiety tinggi yang berhasil diprediksi sebagai anxiety tinggi oleh model, sedangkan *true negative* (TN) adalah jumlah sampel anxiety rendah yang berhasil diprediksi sebagai anxiety rendah. *False positive* (FP) menunjukkan sampel anxiety rendah yang keliru diprediksi sebagai *anxiety* tinggi, sementara *false negative* (FN) menunjukkan sampel *anxiety* tinggi yang keliru diprediksi sebagai *anxiety* rendah. Pendefinisian ini mengikuti konvensi umum dalam evaluasi klasifikasi biner.

Nilai-nilai pada *confusion matrix* selanjutnya digunakan sebagai dasar dalam perhitungan metrik evaluasi kinerja model. Metrik yang digunakan dalam penelitian ini meliputi *accuracy*, *precision*, dan *recall* yang dihitung menggunakan persamaan berikut.

a. Accuracy

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

b. Precision

$$precision = \frac{TP}{TP + FP}$$

c. Recall

$$recall = \frac{TP}{TP + FN}$$

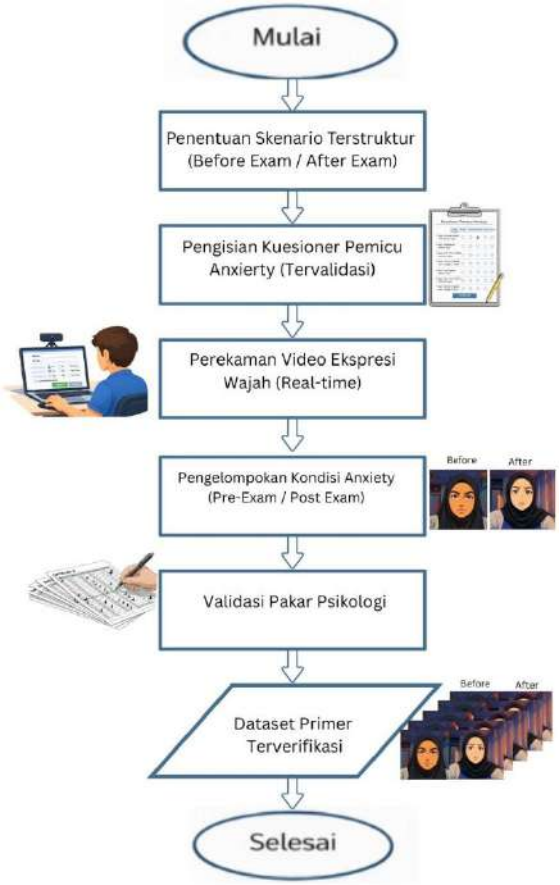
BAB III. METODOLOGI PENELITIAN

3.1 Waktu dan Tempat Penelitian

Penelitian ini dilaksanakan di Politeknik Negeri Malang, khususnya di Laboratorium IVSS (*Intelligent Vision and Smart System*) pada Gedung Jurusan Teknik Informatika. Subjek penelitian adalah mahasiswa dan mahasiswi semester V Program Studi Teknik Informatika dengan rentang usia 20-22 tahun, yang dipilih secara acak. Partisipan mencakup mahasiswa yang memiliki gangguan kecemasan (*anxiety*) maupun yang tidak, sehingga variasi kondisi psikologis dapat terwakili. Penelitian ini difokuskan pada mahasiswa yang sedang atau akan menjalani Ujian Akhir Semester, dengan tujuan memperoleh gambaran kondisi kecemasan yang muncul dalam situasi evaluasi akademik. Data yang digunakan merupakan data primer, yang diperoleh melalui proses pengumpulan data secara langsung dengan melibatkan pihak-pihak terkait sesuai dengan objek penelitian.

3.2 Teknik Pengumpulan Data

Penelitian ini menggunakan data ekspresi wajah pada kondisi normal dan kondisi individu yang mengalami gangguan kecemasan (*anxiety*) sebagai data primer. Data diperoleh melalui proses pengumpulan langsung yang melibatkan subjek penelitian sebagai sumber utama. Pengambilan data dilakukan dengan berkoordinasi bersama pihak-pihak yang terlibat secara langsung dalam proses akuisisi data. Secara garis besar, proses pengumpulan data dirancang dan dilaksanakan dalam tiga tahapan utama, sebagaimana yang ditunjukkan pada Gambar 3.1.



Gambar 3.1 Alur Pengumpulan Data Primer Penelitian

1. Tahapan Awal

   Tahapan awal adalah tahapan persiapan sebelum dilakukan pengambilan data ekspresi wajah. Pada tahapan ini akan dilakukan.

   a. Penentuan skenario pengambilan data dilakukan dengan menetapkan dua kondisi pengambilan, yaitu sebelum (*before*) dan sesudah (*after*) responden mengikuti Ujian Akhir Semester. Penetapan dua kondisi ini bertujuan untuk menangkap perbedaan respons kecemasan pada fase pra dan pasca ujian, sesuai dengan karakteristik kecemasan yang dapat muncul sebelum maupun setelah peristiwa pemicu.

   b. Penyusunan kuesioner dilakukan dengan merancang pertanyaan yang berkaitan dengan pemicu munculnya perasaan cemas. Kuesioner ini disusun dengan mengacu pada

penelitian *Faces Anxiety Scale as a Screening Measure of Preoperative Anxiety: Validation and Diagnostic Accuracy Study* yang dilakukan oleh Jana Turzáková, Tomáš Sollár, dan Andrea Solgajová, yang menggunakan instrumen *Faces Anxiety Scale* (FAS). Selain itu, proses validasi kuesioner juga melibatkan penggunaan instrumen *Spielberger State-Trait Anxiety Inventory* (STAI) dan *Hospital Anxiety and Depression Scale* (HADS). Seluruh instrumen tersebut diterjemahkan ke dalam Bahasa Indonesia sebelum digunakan. Proses penyusunan dan validasi kuesioner dilaksanakan dengan pendampingan pakar, yaitu Prof. Dr. Adi Atmoko, M.Pd., dosen Fakultas Ilmu Pendidikan Universitas Negeri Malang dengan kepakaran di bidang bimbingan dan konseling.

c. Pengisian kuesioner tahap pertama menggunakan enam pernyataan awal. Hasil pengisian ini digunakan untuk mengevaluasi kejelasan pemahaman responden dan kesesuaian butir terhadap kecemasan. Berdasarkan hasil evaluasi dan masukan pakar, satu butir pertanyaan yang dinilai kurang representatif dieliminasi, sehingga diperoleh lima pertanyaan akhir yang digunakan pada tahap berikutnya.
d. Pengisian kuisioner tahap kedua dengan menggunakan lima pertanyaan terpilih oleh calon objek penelitiaan sekaligus penentuan kelompok jenis kecemasannya. Tabel 3.1 merupakan contoh pertanyaan pada kuesioner.

Table 3.1 Pertanyaan Kuisoner *Faces Anxiety Scale* (FAS)

NO	Pertanyaan	1	2	3	4
1.	Saya merasakan semacam perasaan takut seperti ulat di perut				
2.	Saya merasakan semacam perasaan takut, seolah-olah sesuatu yang buruk akan terjadi				
3.	Saya merasa gelisah karena saya				

	harus terus bergerak				
4.	Pikiran-pikiran yang mengkhawatirkan muncul di benak saya				
5.	Saya tiba-tiba merasa panik				

Skala yang digunakan pada pengisian kuesioner adalah sebagai berikut:

- 1 = Sangat Tidak Setuju
- 2 = Tidak setuju
- 3 = Setuju
- 4 = Sangat Setuju

e. Pelabelan data dilakukan berdasarkan hasil kuesioner pada tingkat responden. Skor total kuesioner diperoleh dari penjumlahan nilai seluruh pernyataan, dengan rentang skor 1-20. Rentang skor 1-10 dikategorikan sebagai *anxiety* rendah, sedangkan rentang skor 11-20 dikategorikan sebagai *anxiety* tinggi. Seluruh video ekspresi wajah yang direkam dari satu responden diberi label yang sama sesuai kategori tingkat kecemasan tersebut. Apabila hasil kuesioner menunjukkan tingkat kecemasan tinggi, maka seluruh video responden tersebut diberi label *anxiety* tinggi, dan sebaliknya untuk *anxiety* rendah.

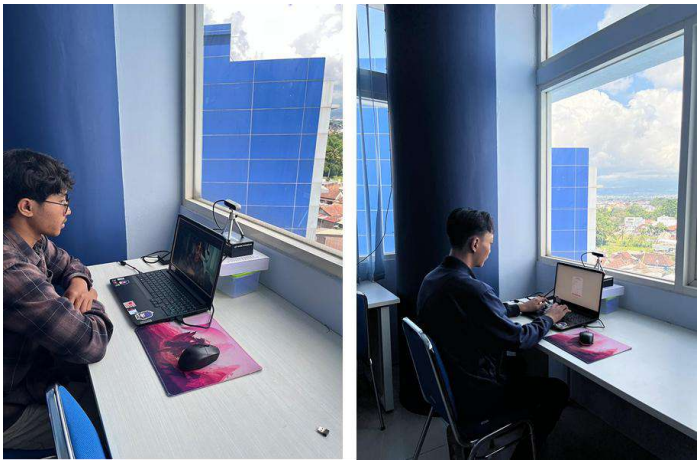
f. Sebelum melakukan pengumpulan data, dikembangkan sebuah aplikasi kuesioner yang digunakan sebagai media penelitian. Aplikasi ini dirancang untuk mendukung proses pengisian kuesioner sekaligus memfasilitasi perekaman video ekspresi wajah responden selama proses pengisian berlangsung. Melalui aplikasi tersebut, proses pengambilan data dapat dilakukan secara terstruktur dan terintegrasi, sehingga data kuesioner dan data visual yang dihasilkan

memiliki keterkaitan langsung dengan setiap pertanyaan yang dijawab oleh responden.

2. Tahapan Perekaman

Tahapan perekaman merupakan tahap pengambilan data ekspresi wajah dari subjek penelitian yang telah ditentukan. Pada tahap ini, responden diminta untuk mengisi serta memberikan persetujuan melalui lembar *informed consent* terkait penggunaan data yang diperoleh untuk keperluan penelitian. Perekaman ekspresi wajah dilakukan sesuai dengan skenario pengambilan data yang telah ditetapkan pada tahap sebelumnya. Pengumpulan data dilakukan dalam bentuk rekaman video yang diambil secara langsung saat responden mengisi kuesioner melalui aplikasi yang dikembangkan, sehingga proses perekaman berlangsung secara natural sesuai dengan respons responden. Setiap pertanyaan pada kuesioner menghasilkan satu rekaman video, sehingga satu kuesioner lengkap menghasilkan beberapa video yang tersegmentasi berdasarkan masing-masing pertanyaan. Seluruh hasil perekaman selanjutnya dikelompokkan berdasarkan kondisi waktu pengambilan data, yaitu *before* dan *after*, untuk mendukung analisis perbedaan ekspresi wajah pada kedua kondisi tersebut. Aktivitas perekaman ini dilakukan menggunakan dua perangkat kamera yang telah terintegrasi ke dalam aplikasi, yaitu:

- Intel RealSense D415, digunakan sebagai kamera utama dengan pengaturan dengan resolusi 640 × 480 piksel dan frame rate 60 frame per detik (FPS), yang diharapkan mampu menangkap perubahan ekspresi wajah secara lebih halus.
- Webcam bawaan laptop Lenovo IdeaPad Gaming (HD 720p *with Privacy Shutter* dan 30 fps), digunakan sebagai kamera cadangan apabila terjadi kendala teknis pada kamera utama.



Gambar 3.2 Proses pengambilan data



Gambar 3.3 contoh Dataset dalam bentuk *frame*

3. Tahapan Validasi

Tahapan validasi merupakan tahap pelabelan data berdasarkan indikator kecemasan yang telah ditetapkan dengan memanfaatkan hasil perekaman video yang sebelumnya telah tersegmentasi secara otomatis berdasarkan setiap pertanyaan kuesioner dan kondisi pengambilan data (*before* dan *after*). Seluruh video hasil perekaman divalidasi oleh pakar, yaitu Prof. Dr. Adi Atmoko, M.Pd., dosen Fakultas Ilmu Pendidikan Universitas Negeri Malang dengan kepakaran di bidang bimbingan dan konseling, dengan mempertimbangkan hasil pengisian kuesioner responden sebagai dasar penentuan label kondisi kecemasan. Berdasarkan hasil validasi tersebut, data dikelompokkan ke dalam kategori *anxiety* tinggi dan

anxiety rendah sesuai label yang ditetapkan, kemudian digunakan sebagai dataset akhir pada tahap pemodelan dan analisis.

3.3 Teknik Pengolahan Data

Teknik pengolahan data dalam penelitian ini dilaksanakan melalui dua tahap utama yang saling berkaitan guna memastikan kualitas dataset yang digunakan. Tahap pertama berupa pengolahan data kuesioner yang diperoleh dari responden. Data hasil pengisian kuesioner dihitung menggunakan sistem skoring yang telah ditetapkan oleh pakar psikologi, di mana setiap respons dijumlahkan untuk menghasilkan skor total. Berdasarkan skor total tersebut, tingkat kecemasan diklasifikasikan ke dalam empat kategori, yaitu kecemasan sangat rendah, rendah, tinggi, dan sangat tinggi. Penentuan kategori kecemasan ini dilakukan berdasarkan skema *scoring* yang telah ditetapkan dan divalidasi oleh pakar, sebagaimana disajikan pada Tabel 3.3.

Tabel 3.1 Kategorisasi dan skor

Kategori	**Rentang Skor**
Anxiety Tinggi	11-20
Anxiety Rendah	1-10

Tahap kedua merupakan tahap validasi dan seleksi data video ekspresi wajah yang berperan penting dalam memastikan kesesuaian antara data visual dan tingkat kecemasan yang terukur. Seluruh video yang diperoleh dari responden melalui proses perekaman divalidasi oleh Prof. Dr. Adi Atmoko, M.Pd., sebagai pakar psikologi yang memiliki kompetensi dalam menilai ekspresi emosi dan kecemasan. Proses validasi ini dilakukan untuk memastikan bahwa ekspresi wajah yang terekam dalam video selaras dengan tingkat kecemasan yang diindikasikan berdasarkan hasil pengisian kuesioner. Data video yang tidak menunjukkan konsistensi antara ekspresi visual dan skor kecemasan yang diperoleh akan dikeluarkan dari dataset guna menjaga kualitas dan integritas data penelitian.

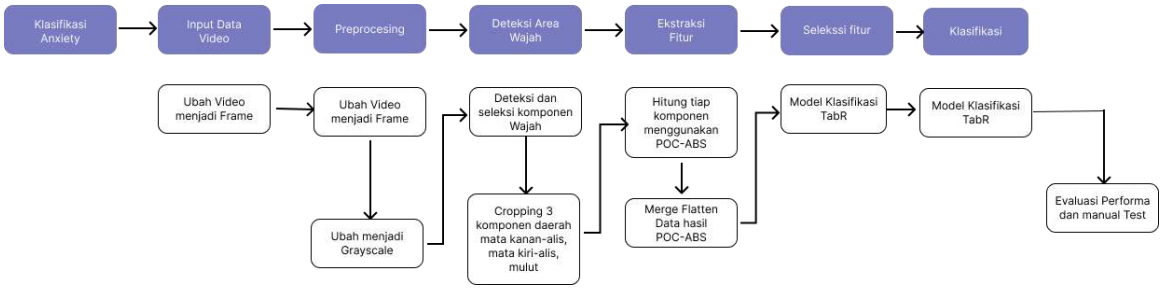
Kriteria eliminasi ditetapkan untuk menyaring data yang tidak layak digunakan, meliputi ketidaksesuaian ekspresi wajah dengan indikator kecemasan serta kualitas video yang tidak memenuhi standar. Hanya video yang

telah tervalidasi dan memenuhi seluruh persyaratan kualitas yang digunakan sebagai dataset pengujian dalam pengembangan model klasifikasi. Proses validasi dan seleksi data ini dilakukan secara ketat untuk menjamin kualitas data dan konsistensi *ground truth* pada pemodelan berbasis *Deep Learning*, sehingga model yang dihasilkan mampu mengklasifikasikan tingkat kecemasan berdasarkan ekspresi wajah secara akurat dan konsisten.

3.4 Desain Sistem

Desain sistem pengenalan *micro-expression* penderita *anxiety* pada penelitian ini dirancang untuk menganalisis data video wajah dan mengidentifikasi pola *micro-expression* yang mengindikasikan kondisi kecemasan. Sistem ini mengintegrasikan teknik *computer vision* dan *deep learning* untuk menghasilkan klasifikasi kondisi *anxiety*.

Sistem yang diusulkan terdiri atas enam tahap utama, yaitu *input* data video, *preprocessing*, deteksi area komponen wajah, ekstraksi fitur, seleksi fitur, dan klasifikasi. Alur kerja sistem pengenalan *micro-expression* penderita *anxiety* pada penelitian ini mengikuti tahapan yang ditunjukkan pada Gambar

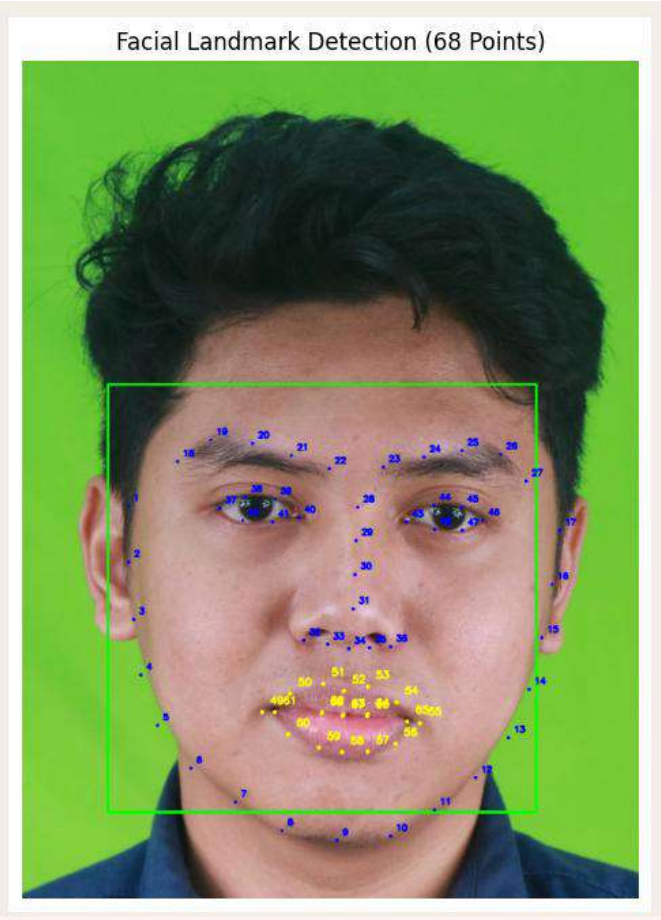


Gambar 3.4 Desain Sistem

Tahap pertama yaitu input data video yang dilanjutkan dengan proses *preprocessing*, di mana video yang diinputkan akan diubah menjadi frame. Setiap frame kemudian dikonversi ke dalam format grayscale agar memudahkan proses pengolahan citra.

Pada tahap deteksi area komponen wajah, sistem memanfaatkan pustaka Dlib untuk mendeteksi wajah serta menentukan 68 titik *facial landmark* sebagai acuan penentuan lokasi komponen wajah. Berdasarkan titik-titik *landmark* tersebut, sistem mengidentifikasi area wajah yang relevan untuk

analisis *micro-expression*. Visualisasi hasil deteksi *facial landmark* dan penentuan area wajah ditunjukkan pada Gambar 3.5.



Gambar 3.5 Deteksi 68 *Facial Landmark* menggunakan Dlib

Setelah wajah berhasil terdeteksi, dilakukan proses *cropping* pada tiga area komponen utama yang berperan penting dalam ekspresi wajah, yaitu daerah mata kanan-alis, mata kiri-alis, dan mulut. Penentuan area *cropping* dilakukan berdasarkan indeks *facial landmark* 68 titik yang digunakan sebagai acuan lokasi komponen wajah. Konfigurasi area komponen wajah pada penelitian ini ditetapkan sebagai berikut:

- Area mulut ditentukan oleh landmark 48-67.
- Area mata-alis kiri ditentukan oleh landmark 17-21 (alis) dan 36-41(mata).
- Area mata-alis kanan ditentukan oleh landmark 22-26 (alis) dan 42-47 (mata).

- Setiap *region of interest* (ROI) diperluas menggunakan padding horizontal sebesar 6 piksel dan padding vertikal sebesar 8 piksel untuk memastikan area ekspresi tercakup secara optimal.
- Hasil *cropping* setiap ROI kemudian dinormalisasi ke ukuran tetap, yaitu 70 × 35 piksel untuk area mulut serta 48 × 32 piksel untuk area mata–alis kiri dan mata–alis kanan.

Contoh hasil *cropping* pada masing-masing komponen wajah ditunjukkan pada Gambar 3.6.



Gambar 3.6 Hasil *cropping* area mata-alis kanan, mata-alis kiri, dan mulut

Tahap berikutnya yaitu ekstraksi fitur, di mana setiap area komponen wajah hasil *cropping* dihitung nilai fiturnya menggunakan metode *Phase Only Correlation with All Block Search* (POC-ABS). Proses ini dilakukan pada masing-masing komponen wajah untuk menangkap pergerakan halus yang merepresentasikan *micro-expression*. Seluruh fitur hasil ekstraksi kemudian digabungkan dan diratakan melalui proses *merge* dan *flatten* sehingga membentuk data tabular yang siap digunakan pada tahap klasifikasi. Contoh struktur data yang dihasilkan oleh metode POC-ABS dapat dilihat pada Tabel berikut:

Sample	**ROI Mata-Alis Kanan**	**ROI Mata-Alis Kiri**	**ROI Mulut**	**Label**
S1	(X_1, Y_1, θ_1, M_1)	(X_2, Y_2, θ_2, M_2)	(X_3, Y_3, θ_3, M_3)	Anxiety
S2	(X_1, Y_1, θ_1, M_1)	(X_2, Y_2, θ_2, M_2)	(X_3, Y_3, θ_3, M_3)	Normal

Tabel 3.2 Contoh bentuk hasil data

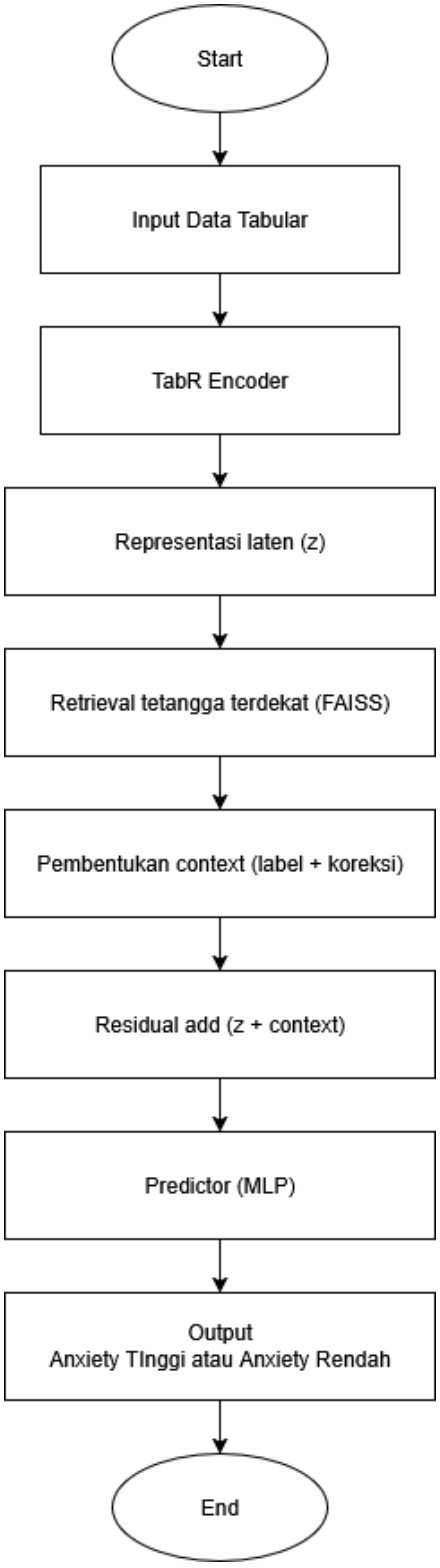
Data terdiri dari tiga kelompok fitur berdasarkan *region of interest* (ROI), yaitu mata-alis kanan, mata-alis kiri, dan mulut. Setiap *region of interest* (ROI) direpresentasikan oleh beberapa parameter fitur sebagai berikut:

- X: pergeseran horizontal antar-frame yang merepresentasikan gerakan mikro ke arah kiri atau kanan.
- Y: pergeseran vertikal antar-frame yang merepresentasikan gerakan mikro ke arah atas atau bawah.
- θ (theta): arah dominan pergerakan wajah yang menunjukkan orientasi vektor gerak.
- Magnitudo: besar intensitas pergerakan yang menggambarkan kekuatan gerakan mikro hasil POC-ABS.

Karena seluruh fitur bersifat numerik dan terstruktur dalam bentuk vektor satu dimensi, data hasil ekstraksi POC-ABS sangat sesuai untuk diproses menggunakan model *Tabular Retrieval Network* (TabR) yang memang dirancang untuk menangani data tabular dan memodelkan relasi kompleks antar fitur secara efektif. Pada tahap selanjutnya, data tabular hasil ekstraksi digunakan sebagai masukan ke dalam model klasifikasi TabR untuk melakukan klasifikasi kondisi *anxiety*.

3.4.1 Pembuatan Model

Pada tahap ini dilakukan pembuatan model klasifikasi kondisi anxiety menggunakan *Tabular Retrieval Network* (TabR). Model TabR digunakan untuk mengklasifikasikan kondisi kecemasan berdasarkan data tabular hasil ekstraksi fitur *micro-expression* yang telah melalui tahap *preprocessing*, validasi, dan pembentukan dataset. Alur kerja model TabR yang digunakan dalam penelitian ini ditunjukkan pada Gambar 3.7.



Gambar 3.7 Alur model TabR

1. Persiapan dan Pra-pemrosesan Data

Data yang digunakan dalam pembuatan model berupa data tabular hasil proses *merge* dan *flatten* dari seluruh fitur *micro-expression*.

Sebelum digunakan pada proses pelatihan dan inferensi, dilakukan penyeimbangan jumlah data antar kelas untuk mengurangi bias distribusi kelas. Selanjutnya, data diproses menggunakan *imputer* untuk menangani nilai kosong serta *scaler* untuk menormalkan skala fitur. Tahapan ini bertujuan untuk memastikan bahwa distribusi kelas dan skala fitur berada dalam kondisi yang konsisten. Hasil dari tahap ini digunakan sebagai masukan langsung ke *encoder* model.

2. Pembentukan Model TabR dan Mekanisme Context

   Model TabR dibangun dengan memanfaatkan jaringan saraf *feed-forwar*d sebagai *encoder* untuk memetakan data tabular ke dalam representasi fitur laten. Representasi laten ini digunakan digunakan sebagai dasar pengukuran kemiripan dengan data latih.

   Selain memanfaatkan informasi dari data masukan, model juga menggunakan mekanisme *context* yang berasal dari data latih. *Context* berfungsi sebagai sumber informasi tambahan yang memungkinkan model mempertimbangkan kemiripan antar sampel, sehingga proses klasifikasi tidak hanya bergantung pada informasi individual, tetapi juga pada pola lokal dalam data pelatihan.

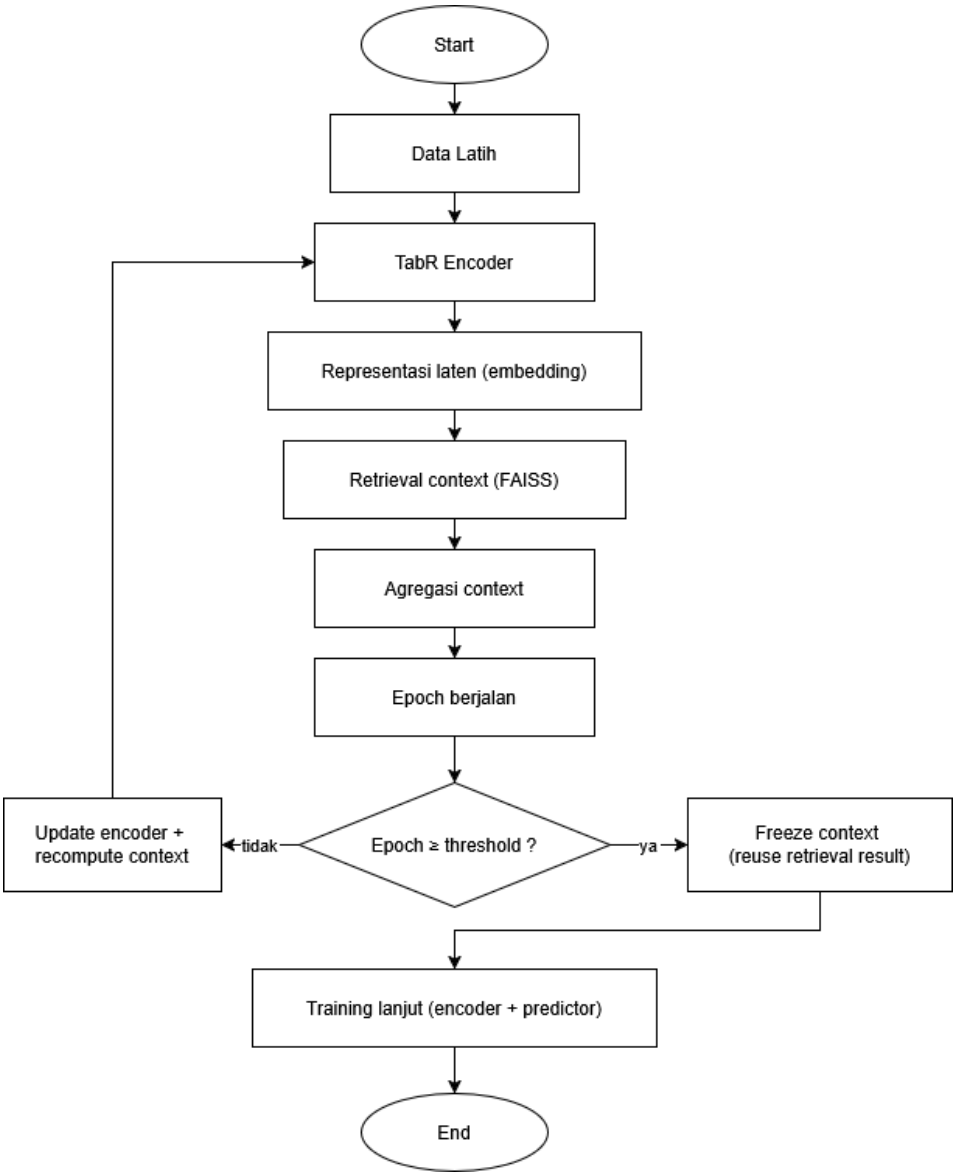
3. *Retrieval* Berbasis FAISS

   Untuk mengakses informasi context secara efisien, digunakan mekanisme *retrieval* berbasis FAISS. Representasi *query* dari data masukan digunakan untuk mencari sejumlah sampel *context* terdekat berdasarkan kemiripan representasi laten. Sampel *context* terpilih kemudian disesuaikan sebelum digabungkan dengan representasi fitur utama, sehingga informasi *context* yang relevan dapat memperkaya proses pengambilan keputusan model.

4. Tahapan *Context Freezing* pada Proses Pelatihan

   Pada tahap pelatihan, mekanisme *context* pada model TabR dibentuk dan diperbarui secara bertahap sebagaimana ditunjukkan pada Gambar 3.8. Pada fase awal, data latih diproses oleh *encoder* untuk menghasilkan representasi laten (*embedding*), yang digunakan sebagai dasar pembentukan *context* melalui proses *retrieval*. Pada fase ini,

parameter *encoder* diperbarui dan *context* dihitung ulang pada setiap *epoch*.



Gambar 3.8 Proses *Context Freezing*

Setelah jumlah *epoch* mencapai nilai ambang yang ditetapkan, dilakukan proses *context freezing*, yaitu penghentian pembaruan *context* hasil *retrieval*. *Context* yang telah dibekukan selanjutnya digunakan sebagai *context memory* tetap, sementara proses pelatihan difokuskan pada penyempurnaan bagian *encoder* dan *predictor*. Pendekatan ini bertujuan untuk meningkatkan efisiensi dan menjaga stabilitas pembelajaran.

5. Konfigurasi Model

Pelatihan model TabR dilakukan dengan konfigurasi sebagai berikut:

a. Jumlah *external context* (n_external): 2, yang digunakan untuk memanfaatkan sejumlah sampel konteks terdekat dalam proses *retrieval* guna memperkaya representasi input.
b. *Batch size*: 128, dipilih untuk menjaga keseimbangan antara stabilitas pembaruan bobot dan efisiensi komputasi selama proses pelatihan.
c. Jumlah maksimum *epoch*: 50, ditetapkan untuk memberikan kesempatan model mempelajari pola data secara optimal tanpa menyebabkan pelatihan berlebihan.

Model dilatih secara iteratif menggunakan data pelatihan, dengan performa yang dipantau melalui data validasi pada setiap *epoch*. Evaluasi pada data validasi digunakan untuk mengamati perkembangan pembelajaran model dan menjaga stabilitas proses pelatihan. Model yang telah dilatih selanjutnya disimpan dan digunakan pada tahap evaluasi serta pengujian performa sistem.

3.4.2 zEvaluasi Model

Pada tahap ini dilakukan evaluasi terhadap model Tabular Retrieval Network (TabR) yang telah dilatih untuk menilai performa klasifikasi kondisi *anxiety* tinggi dan *anxiety* rendah. Evaluasi difokuskan pada pemantauan perubahan nilai akurasi dan *loss* pada data pelatihan dan validasi di setiap *epoch*.

1. Monitoring Proses Pelatihan

Evaluasi dilakukan dengan memantau grafik *training* dan *validation accuracy* serta *training* dan *validation loss*. Grafik akurasi digunakan untuk mengamati peningkatan kemampuan klasifikasi model seiring bertambahnya *epoch*, sedangkan grafik *loss* digunakan untuk mengevaluasi proses konvergensi model selama pelatihan.

Perbandingan antara kurva pelatihan dan validasi digunakan untuk mengidentifikasi kestabilan proses pembelajaran serta indikasi awal terjadinya *overfitting* atau *underfitting*. Grafik ini berfungsi sebagai

evaluasi awal untuk memastikan bahwa model TabR mampu belajar secara konsisten sebelum dilakukan evaluasi klasifikasi berbasis metrik.

2. Skema Evaluasi

Data evaluasi terdiri atas dua skema, yaitu evaluasi internal dan evaluasi eksternal. Evaluasi internal dilakukan menggunakan data validasi yang berasal dari data pelatihan, sedangkan evaluasi eksternal dilakukan menggunakan data uji berbasis subjek yang tidak dilibatkan dalam proses pelatihan maupun pembentukan *context*. Seluruh data evaluasi telah melalui proses *preprocessing* yang sama dengan data pelatihan, meliputi penyeimbangan kelas, imputasi nilai kosong, dan normalisasi fitur, guna menjaga konsistensi distribusi data.

3. *Confusion Matrix*

Confusion matrix digunakan sebagai alat utama untuk mengevaluasi kinerja model *Tabular Retrieval Network* (TabR) dalam mengklasifikasikan kondisi *anxiety* tinggi dan *anxiety* rendah. Matriks ini membandingkan hasil prediksi model dengan label sebenarnya yang terdiri dari *true positive*, *true negative*, *false positive*, dan *false negative*, sehingga memungkinkan analisis terhadap pola kesalahan klasifikasi yang terjadi. Berdasarkan *confusion matrix* tersebut, dihitung metrik evaluasi yang meliputi *accuracy*, *precision*, *recall*, dan *F1-score* untuk memberikan gambaran menyeluruh mengenai performa model dalam mengklasifikasikan masing-masing kelas.

4. Interpretasi Hasil Evaluasi

Hasil evaluasi dianalisis untuk menilai tingkat akurasi model serta keseimbangan performa antar kelas. Analisis terhadap nilai *precision* dan *recall* dilakukan untuk menilai kemampuan model dalam mendeteksi kondisi *anxiety* secara tepat, sedangkan nilai *F1-score* digunakan sebagai indikator performa keseluruhan yang mempertimbangkan keseimbangan antara *precision* dan *recall*.

3.4.3 Arsitektur Sistem

Sistem dirancang dengan komponen utama sebagai berikut:

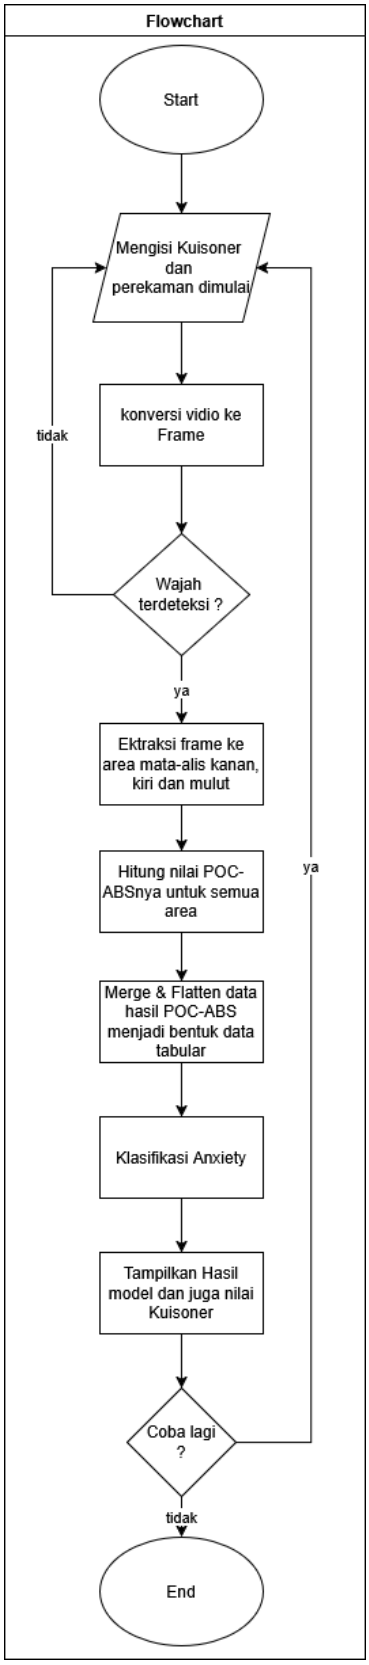
a. *Fullstack Web Application*

   Aplikasi web dikembangkan menggunakan TanStack Start sebagai framework *fullstack* yang menangani antarmuka pengguna dan logika aplikasi secara terpadu. Pada sisi klien, aplikasi memanfaatkan React, TypeScript, dan Tailwind CSS untuk pengisian kuesioner, perekaman video melalui browser, serta visualisasi hasil secara *real-time*. Pada sisi server, TanStack Start digunakan untuk pengelolaan logika aplikasi, validasi data, manajemen sesi pengguna, serta integrasi dengan Supabase sebagai layanan basis data dan *autentikasi* berbasis PostgreSQL.

b. *Backend* Integrasi dengan Model *Deep Learning*

   Proses pemrosesan video dan inferensi model *deep learning* diimplementasikan menggunakan FastAPI berbasis Python. Komponen ini bertanggung jawab dalam melakukan *preprocessing* data, ekstraksi fitur *micro-expression*, pembentukan data tabular, serta klasifikasi kondisi *anxiety* menggunakan model *Tabular Retrieval Network* (TabR) yang telah dilatih sebelumnya.

3.4.4 Alur Proses Sistem



Gambar 3.9 Diagram Alur

Alur kerja sistem yang ditunjukkan pada Gambar 3.3 Diagram Alur Proses Sistem dapat dijelaskan melalui langkah-langkah berikut:

1. Pengisian Kuesioner dan Perekaman Video

   Proses dimulai ketika responden mengisi kuesioner melalui antarmuka web, diikuti dengan perekaman video ekspresi wajah menggunakan kamera yang terhubung ke sistem.

2. Preprocessing Data Video

   Video hasil perekaman diubah menjadi rangkaian frame, kemudian dilakukan konversi ke format *grayscale* dan penyesuaian ukuran untuk menyiapkan data sebelum tahap analisis.

3. Deteksi Wajah dan Ekstraksi Fitur

   Sistem mendeteksi wajah pada setiap frame dan mengekstraksi area mata–alis kanan, mata–alis kiri, dan mulut. Area tersebut dianalisis menggunakan metode POC-ABS untuk memperoleh fitur *micro-expression*.

4. Klasifikasi dan Hasil Analisis

   Fitur hasil ekstraksi digabungkan menjadi data tabular dan diklasifikasikan menggunakan model *Tabular Retrieval Network* (TabR). Hasil klasifikasi kemudian ditampilkan melalui antarmuka web.

3.5 Uji Coba Sistem

Pada tahap ini dilakukan pengujian sistem untuk menilai kinerja sistem dalam mendeteksi dan mengklasifikasikan data serta mengukur tingkat akurasi sistem. Pengujian difokuskan pada aspek evaluasi akurasi menggunakan model yang diterapkan.

DAFTAR PUSTAKA

American Psychiatric Association. (2022). Diagnostic and Statistical Manual of Mental Disorders: Fifth Edition Text Revision DSM-5-TR™. *American Psychiatric Association*. https://doi.org/10.1176/appi.books.9780890425787

Archana, R., & Jeevaraj, P. S. E. (2024). Deep learning models for digital image processing: A review. *Artificial Intelligence Review*, *57*(1), 11. https://doi.org/10.1007/s10462-023-10631-z

Arik, S. Ö., & Pfister, T. (2021). TabNet: Attentive Interpretable Tabular Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, *35*(8), 6679–6687. https://doi.org/10.1609/aaai.v35i8.16826

Ben, X., Ren, Y., Zhang, J., Wang, S.-J., Kpalma, K., Meng, W., & Liu, Y.-J. (2021). Video-based Facial Micro-Expression Analysis: A Survey of Datasets, Features and Algorithms. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1–1. https://doi.org/10.1109/TPAMI.2021.3067464

Bin Talib, K. H., Xu, K., Cao, Y., Ping Xu, Y., Xu, Z., Zaman, M., & Akhunzada, A. (2025). Micro-Expression Recognition Using Convolutional Variational Attention Transformer (ConVAT) With Multihead Attention Mechanism. *IEEE Access*, *13*, 20054–20070. https://doi.org/10.1109/ACCESS.2025.3530114

Chen, J., Zhao, X., Xiong, Z., & Liu, G. (2025). EEG-Based Micro-Expression Recognition: Flexible Brain Network Reconfiguration Supporting Micro-Expressions Under Positive Emotion. *Psychology Research and Behavior Management*, *Volume 18*, 781–796. https://doi.org/10.2147/PRBM.S506311

Chen, S., & Zhong, C. (2025). Mental health assessment model for college students based on facial expression recognition. *Scientific Reports*, *15*(1), 45413. https://doi.org/10.1038/s41598-025-29461-w

Choirina, P., Rosiani, U. D., & Fitriani, I. M. (2022). Pengenalan Ekspresi Mikro Wajah Berdasarkan Point Feature Tracking Menggunakan Fase Apex Pada

Database Ekspresi Mikro. *Edu Komputika Journal*, *9*(1), 28–36. https://doi.org/10.15294/edukomputika.v9i1.56600

Coppini, S., Lucifora, C., Vicario, C. M., & Gangemi, A. (2023). Experiments on real-life emotions challenge Ekman's model. *Scientific Reports*, *13*(1), 9511. https://doi.org/10.1038/s41598-023-36201-5

Dawel, A., Krumhuber, E. G., & Palermo, R. (2025). Faking It Isn't Making It: Research Needs Spontaneous and Naturalistic Facial Expressions. *Affective Science*. https://doi.org/10.1007/s42761-025-00320-1

Dewi, A. D. A., Muniandy, N. D., Subardjo, R. Y. S., Nurmaguphita, D., & Fauzia, F. R. (2025). The correlation between mental health and eating behavior in Indonesian college students: A cross-sectional study. *JHeS (Journal of Health Studies)*, *9*(1), 71–79. https://doi.org/10.31101/jhes.4023

Dong, Z., Wang, G., Lu, S., Li, J., Yan, W., & Wang, S.-J. (2022). Spontaneous Facial Expressions and Micro-expressions Coding: From Brain to Face. *Frontiers in Psychology*, *12*, 784834. https://doi.org/10.3389/fpsyg.2021.784834

Ghafarfaraji, S. (2025). AI-based recognition of facial and micro-expressions for the diagnosis of mental and neurological disorders: A systematic review. *BMC Psychiatry*. https://doi.org/10.1186/s12888-025-07739-7

Gorishniy, Y., Rubachev, I., Kartashev, N., Shlenskii, D., Kotelnikov, A., & Babenko, A. (2024). *TABR: TABULAR DEEP LEARNING MEETS NEAREST NEIGHBORS*. https://doi.org/10.48550/arXiv.2307.14338

Huang, J.-T., Sharma, A., Sun, S., Xia, L., Zhang, D., Pronin, P., Padmanabhan, J., Ottaviano, G., & Yang, L. (2020). Embedding-based Retrieval in Facebook Search. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2553–2561. https://doi.org/10.1145/3394486.3403305

Kim, M., Cho, Y., & Kim, S.-Y. (2022). Effects of diagnostic regions on facial emotion recognition: The moving window technique. *Frontiers in Psychology*, *13*, 966623. https://doi.org/10.3389/fpsyg.2022.966623

Lei, J., Leigh, E., Charman, T., Russell, A., & Hollocks, M. J. (2024). Exploring the association between social camouflaging and self- versus caregiver-report

discrepancies in anxiety and depressive symptoms in autistic and non-autistic socially anxious adolescents. *Autism*, *28*(10), 2657–2674. https://doi.org/10.1177/13623613241238251

Li, J., Wang, S.-J., Wang, Y., Zhou, H., & Fu, X. (2025). Parallel Spatiotemporal Network to recognize micro-expression. *Neurocomputing*, *636*, 129891. https://doi.org/10.1016/j.neucom.2025.129891

Li, Y., Wei, J., Liu, Y., Kauttonen, J., & Zhao, G. (2022). Deep Learning for Micro-Expression Recognition: A Survey. *IEEE Transactions on Affective Computing*, *13*(4), 2028–2046. https://doi.org/10.1109/TAFFC.2022.3205170

Liu, Yanju, Li, Y., Yi, X., Hu, Z., Zhang, H., & Liu, Yanzhong. (2022). Micro-expression recognition model based on TV-L1 optical flow method and improved ShuffleNet. *Scientific Reports*, *12*(1), 17522. https://doi.org/10.1038/s41598-022-21738-8

Lu, S., Li, J., Wang, Y., Dong, Z., Wang, S.-J., & Fu, X. (2022). A More Objective Quantification of Micro-Expression Intensity through Facial Electromyography. *Proceedings of the 2nd Workshop on Facial Micro-Expression: Advanced Techniques for Multi-Modal Facial Expression Analysis*, 11–17. https://doi.org/10.1145/3552465.3555038

Möcklinghoff, S., Rapoport, O., & Neidhardt, E. (2024). Examining the role of post-event processing in test anxiety—Pilot testing in three student samples. *International Journal of Educational Research Open*, *7*, 100363. https://doi.org/10.1016/j.ijedro.2024.100363

Nur Cahyo, D., Zulfia Zahro', H., & Vendyansyah, N. (2023). PENGENALAN EKSPRESI MIKRO WAJAH DENGAN EKSTRAKSI FITUR PADA KOMPONEN WAJAH MENGGUNAKAN METODE LOCAL BINARY PATTERN HISTOGRAM. *JATI (Jurnal Mahasiswa Teknik Informatika)*, *7*(1), 822–829. https://doi.org/10.36040/jati.v7i1.6167

Nurshabrina, M. F., Nadira Agustine, S., & Dariyo, A. (2024). Kecemasan Bersekolah pada Anak Pra-Sekolah. *Action Research Literate*, *8*(7), 1784–1789. https://doi.org/10.46799/arl.v8i7.445

Oktamarin, L., Kurniati, F., Sholekhah, M., Nurjanah, S., Oktaria, S. W., Sukmawati, S., & Apriyani, T. (2022). GANGGUAN KECEMASAN (AXIETY DISORDER) PADA ANAK USIA DINI. *Jurnal Multidisipliner Bharasumba*, *1*(02), 119–134. https://doi.org/10.62668/bharasumba.v1i02.192

Pasaribu, J., Yudistira, N., & Mahmudy, W. F. (2024). Tabular Data Classification and Regression: XGBoost or Deep Learning with Retrieval-Augmented Generation. *IEEE Access*, 1–1. https://doi.org/10.1109/ACCESS.2024.3518205

Rosiani, U. D., Choirina, P., Politeknik Negeri Malang, Muna, N., Jember, P. N., Mulyanto, E., Institut Teknologi Sepuluh Nopember, Sumpeno, S., Institut Teknologi Sepuluh Nopember, Purnomo, M., & Institut Teknologi Sepuluh Nopember. (2020). A Novel Approach on Motion Estimation for Micro-Expression Recognition Using Phase Only Correlation with All Block Search (POC-ABS). *International Journal of Intelligent Engineering and Systems*, *13*(6), 546–559. https://doi.org/10.22266/ijies2020.1231.48

Sathyanarayanan, S. (2024). Confusion Matrix-Based Performance Evaluation Metrics. *African Journal of Biomedical Research*, 4023–4031. https://doi.org/10.53555/AJBR.v27i4S.4345

Schwarz, M., Chapman, K., & Häussler, B. (2022). Multilingual Medical Entity Recognition and Cross-lingual Zero-Shot Linking with Facebook AI Similarity Search. *berLEF@SEPLN*, (Computer Science, Medicine). https://ceur-ws.org/Vol-3202/livingner-paper12.pdf

Sejati, R. P. H., & Mardhiyyah, R. (2021). Deteksi Wajah Berbasis Facial Landmark Menggunakan OpenCV Dan Dlib. *Jurnal Teknologi Informasi*, *5*(2), 144–148. https://doi.org/10.36294/jurti.v5i2.2220

Sharma, D., Singh, J., Sehra, S. S., & Sehra, S. K. (2024). Demystifying Mental Health by Decoding Facial Action Unit Sequences. *Big Data and Cognitive Computing*, *8*(7), 78. https://doi.org/10.3390/bdcc8070078

Sinulingga, H. R., & Kong, S. G. (2023). Key-Frame Extraction for Reducing Human Effort in Object Detection Training for Video Surveillance. *Electronics*, *12*(13), 2956. https://doi.org/10.3390/electronics12132956

Watson, D., Clark, L. A., Simms, L. J., & Kotov, R. (2022). Classification and assessment of fear and anxiety in personality and psychopathology. *Neuroscience & Biobehavioral Reviews*, *142*, 104878. https://doi.org/10.1016/j.neubiorev.2022.104878

Yang, S., & Berdine, G. (2024). Confusion matrix. *The Southwest Respiratory and Critical Care Chronicles*, *12*(53), 75–79. https://doi.org/10.12746/swrccc.v12i53.1391

Zhang, He, & Zhang, Hanling. (2022). A Review of Micro-expression Recognition based on Deep Learning. *2022 International Joint Conference on Neural Networks (IJCNN)*, 01–08. https://doi.org/10.1109/IJCNN55064.2022.9892307

Zhao, G., Li, X., Li, Y., & Pietikäinen, M. (2023). Facial Micro-Expressions: An Overview. *Proceedings of the IEEE*, *111*(10), 1215–1235. https://doi.org/10.1109/JPROC.2023.3275192