PENGEMBANGAN SISTEM DETEKSI ANXIETY MENGGUNAKAN METODE MOTION ESTIMATION (POC-ABS) SECARA REALTIME

PROPOSAL SKRIPSI

Oleh:

MUHAMMAD KHALID ATTHORIQ

NIM. 2341720114

PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNOLOGI INFORMASI

POLITEKNIK NEGERI MALANG

2026

DAFTAR ISI

DAFTAR ISI I

BAB I. PENDAHULUAN 1

Latar Belakang 1

Rumusan Masalah 3

Batasan Masalah 3

Tujuan 4

Manfaat 4

BAB II. LANDASAN TEORI 5

Penelitian Terdahulu 5

Dasar Teori 6

Ekspresi Mikro Wajah 6

Kecemasan dan Ekspresi Mikro 8

Facial Landmark dan Dlib 9

Phase Only Correlation with All Block Search (POC-ABS) 10

Data Tabular dan Tabular Retrieval Network (TabR) 14

Metrik Evaluasi 16

BAB III. METODOLOGI PENELITIAN 18

BAB I. PENDAHULUAN

1.1 Latar Belakang

Gangguan kecemasan (*anxiety*) merupakan salah satu permasalahan kesehatan mental yang paling umum di dunia (Javaid et al., 2023). Persoalan utamanya bukan hanya jumlah penderitanya, tetapi keterlambatan dalam mengenalinya. Jumlah psikolog klinis yang terbatas membuat proses skrining dan penanganan dini berpotensi tertunda, sehingga diperlukan alat bantu yang objektif untuk memperkuat pemeriksaan awal. Kebutuhan ini juga terlihat pada kelompok remaja Indonesia, karena hanya sebagian kecil dari mereka yang benar-benar mengakses layanan dukungan atau konseling (Wahdi et al., 2025).

Wajah merupakan kanal komunikasi nonverbal yang paling informatif karena mampu merefleksikan niat, sikap, dan kondisi psikologis seseorang. Selain ekspresi makro yang lazim dijumpai dalam interaksi sehari-hari, emosi juga dapat termanifestasi dalam bentuk yang jauh lebih halus, yaitu *micro-expression*. *Micro-expression* adalah gerakan otot wajah yang berlangsung sangat singkat, muncul tanpa disengaja, dan sulit dikendalikan secara sadar (Oh et al., 2018). Karena sifatnya demikian, *micro-expression* dianggap lebih menggambarkan kondisi emosional yang sebenarnya dibandingkan ekspresi yang dapat disamarkan. Namun, durasinya yang sangat pendek membuat gerakan ini sulit dikenali secara visual, sehingga informasi penting justru terletak pada perubahan antar-*frame* dan bukan pada satu citra tunggal (Rosiani et al., 2020).

Anxiety tidak termasuk dalam kelompok emosi dasar karena secara konsep berbeda dari *fear*. *Fear* merupakan respons terhadap ancaman yang jelas dan dapat diprediksi, sedangkan *anxiety* muncul ketika ancaman bersifat tidak pasti dan berlangsung lebih lama sehingga menimbulkan kewaspadaan yang berkelanjutan (Hur et al., 2020). Individu dengan *anxiety* juga cenderung berusaha menekan atau menyembunyikan emosinya, sehingga sinyal visual kecemasan jarang muncul secara terang-terangan dan lebih banyak tampil sebagai gerakan wajah yang sangat halus (Oh et al., 2018). Hambatan lain datang dari keterbatasan data dan anotasi. Dataset standar seperti CASME II dibangun dengan kategori emosi dasar dan menyediakan kelas cadangan berlabel *others*, sehingga karakteristik visual *anxiety*

tidak terdefinisi dengan jelas (Li et al., 2022). Pengumpulan dan pelabelan data secara mandiri menjadi langkah penting untuk memperoleh gambaran kecemasan yang lebih terkontrol.

Sejalan dengan keterbatasan tersebut, pengembangan metode pengenalan *micro-expression* masih berpusat pada emosi dasar yang tersedia dalam dataset standar. Pendekatan objektif berbasis sinyal visual sebenarnya telah menunjukkan hasil yang menjanjikan, misalnya prediksi tingkat kecemasan dari rekaman video (Gavrilescu & Vizireanu, 2019), deteksi stres berbasis video (Zhang et al., 2020), dan deteksi kecemasan dari kamera ponsel dengan akurasi mencapai 91% (Sahu et al., 2025), tetapi semuanya masih bertumpu pada *action unit* dan fitur geometris. Pola serupa terlihat di Indonesia, di mana deteksi kesehatan mental berbasis pembelajaran mesin lebih banyak menggunakan data fisiologis dan perilaku (Larasati et al., 2024; Prakoso et al., 2026). Dengan demikian, pengkajian *anxiety* melalui representasi pergerakan mikro wajah masih terbuka untuk diteliti.

Untuk menjawab celah tersebut, penelitian ini memodelkan *anxiety* berdasarkan karakteristik pergerakan antar-*frame*, bukan berdasarkan kategori emosi pada dataset standar. Metode *Phase Only Correlation with All Block Search* (POC-ABS) digunakan untuk mengambil pergeseran mikro antar-*frame* dengan membandingkan setiap blok citra pada dua *frame*, sehingga arah dan besar pergeseran halus yang sulit terlihat secara langsung dapat terukur (Rosiani et al., 2020). Hasil ekstraksi berupa nilai numerik yang merepresentasikan arah dan besar pergerakan mikro pada setiap area pengamatan, sehingga setiap sampel menjadi sekumpulan fitur terstruktur atau data tabular. Representasi tersebut selanjutnya dimodelkan menggunakan *Tabular Retrieval Network* (TabR), yaitu jaringan *feed-forward* yang juga mencari sampel terdekat dari data latih untuk memperkuat prediksi (Gorishniy et al., 2024). Dengan pemrosesan yang relatif ringan, pendekatan ini diarahkan pada sistem deteksi *anxiety* yang dapat berjalan secara *realtime*.

Dengan demikian, penelitian ini diharapkan dapat mengisi celah metodologis dalam pengkajian *micro-expression anxiety*, sekaligus menghasilkan

sistem deteksi *anxiety* berbasis *motion estimation* POC-ABS yang mampu membedakan kondisi *anxiety* dan tidak *anxiety* secara objektif dan *realtime*.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah penelitian ini adalah sebagai berikut:

1. Bagaimana fitur pergerakan halus pada area wajah yang diekstraksi menggunakan metode POC-ABS mampu membedakan kondisi *anxiety* dan tidak *anxiety*?
2. Bagaimana performa model TabR dalam mengklasifikasikan kondisi *anxiety* dan tidak *anxiety* berdasarkan fitur POC-ABS, ditinjau dari metrik *accuracy*, *precision*, *recall*, dan *F1-score*?

1.3 Batasan Masalah

Agar penelitian ini lebih terarah dan fokus, penulis menetapkan batasan-batasan masalah sebagai berikut:

1. **Dataset.** Penelitian ini menggunakan dataset *micro-expression anxiety* yang dikumpulkan secara mandiri melalui skema *pre–post* situasi ujian dengan dukungan kuesioner. Pengelompokan label tingkat kecemasan (*anxiety*) dilakukan oleh pakar, yaitu Prof. Dr. Adi Atmoko, M.Pd., dosen Fakultas Ilmu Pendidikan yang memiliki keahlian di bidang bimbingan dan konseling.
2. **Fokus Representasi Emosi.** Penelitian ini difokuskan pada pengenalan kondisi *anxiety* dan tidak *anxiety*, tanpa mengacu pada taksonomi emosi dasar seperti *happiness*, *anger*, *fear*, dan emosi dasar lainnya.
3. **Ekstraksi Pergerakan Mikro Wajah.** Ekstraksi pergerakan mikro wajah dibatasi pada penggunaan metode *Phase Only Correlation with All Block Search* (POC-ABS) untuk merepresentasikan pergeseran mikro antar-*frame*, tanpa membandingkan dengan metode ekstraksi gerakan lainnya.
4. **Area Pengamatan.** Penelitian hanya difokuskan untuk mengamati dan mengambil nilai pada area mata-alis kanan, mata-alis kiri, dan mulut.
5. **Model Klasifikasi.** Pemodelan dan klasifikasi data dilakukan menggunakan *Tabular Retrieval Network* (TabR) berbasis data tabular, tanpa membahas atau

membandingkan dengan model *deep learning* lain seperti CNN atau *transformer* berbasis citra.

6. **Ruang Lingkup Sistem dan Evaluasi.** Penelitian ini dibatasi pada pemrosesan data citra wajah dan evaluasi performa model menggunakan metrik *Accuracy, Precision, Recall,* dan *F1-Score*.

1.4 Tujuan

Berdasarkan rumusan masalah di atas, tujuan dari penelitian ini adalah:

1. Mengidentifikasi dan menganalisis kemampuan fitur pergerakan halus pada area wajah yang diekstraksi menggunakan metode POC-ABS dalam membedakan kondisi *anxiety* dan tidak *anxiety*.
2. Mengevaluasi performa model TabR dalam mengklasifikasikan kondisi *anxiety* dan tidak *anxiety* berdasarkan fitur POC-ABS, ditinjau dari metrik *accuracy, precision, recall,* dan *F1-score*.

1.5 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. **Kontribusi terhadap Analisis Anxiety Berbasis Ekspresi Wajah.** Penelitian ini memberikan kontribusi dalam pengembangan analisis *micro-expression anxiety* pada wajah yang belum banyak dikaji secara eksplisit dalam penelitian *micro-expression* sebelumnya.
2. **Referensi Pengembangan Dataset Micro-Expression Anxiety.** Dataset *pre–post exam* yang dikumpulkan secara mandiri melalui pengisian kuesioner dan perekaman ekspresi wajah dapat menjadi referensi awal bagi penelitian selanjutnya dalam membangun dan mengolah data *micro-expression anxiety* yang bersifat natural dan kontekstual.
3. **Pendekatan Teknis untuk Deteksi Micro-Expression Anxiety.** Pendekatan teknis yang mengombinasikan ekstraksi pergerakan mikro wajah menggunakan *Phase Only Correlation with All Block Search* (POC-ABS) dan pemodelan klasifikasi berbasis data tabular menggunakan *Tabular Retrieval Network* (TabR) dapat menjadi acuan metodologis bagi penelitian selanjutnya dalam mendeteksi emosi wajah yang bersifat halus dan sulit diamati secara visual.

BAB II. LANDASAN TEORI

2.1 Penelitian Terdahulu

Beberapa penelitian yang dijadikan rujukan dalam penelitian ini disajikan pada Tabel 2.1.

Judul Jurnal	**Tahun**	**Metode**	**Hasil Penelitian**
A Novel Approach on Motion Estimation for Micro-Expression Recognition Using POC-ABS (Rosiani et al., 2020)	2020	POC-ABS, SVM, KNN	Akurasi 94,3% (SVM) dan 95,6% (KNN) pada CASME II dengan rata-rata waktu komputasi sekitar 0,03 detik; area alis dominan pada sejumlah ekspresi.
Pengenalan Ekspresi Mikro Wajah Berdasarkan Point Feature Tracking Menggunakan Fase Apex (Choirina et al., 2022)	2022	DRMF, KLT, SVM, MLP	Akurasi 81,3% dengan waktu komputasi rata-rata 1,45 detik per video dengan membatasi area pengamatan pada alis dan sudut bibir.
TabR: Tabular Deep Learning Meets Nearest Neighbors (Gorishniy et al., 2024)	2024	TabR	Peringkat rata-rata terbaik di antara model pembelajaran mendalam untuk data tabular dan pada sejumlah dataset melampaui GBDT, terutama pada data kecil hingga menengah.
Tabular Data Classification and Regression: XGBoost or Deep Learning with Retrieval-Augmented	2024	XGBoost, TabNet, TabR	TabR dengan komponen *retrieval* unggul pada tugas klasifikasi, sedangkan XGBoost tetap unggul pada regresi.

Judul Jurnal	Tahun	Metode	Hasil Penelitian
Generation (Pasaribu et al., 2024)			
Confusion Matrix (Yang & Berdine, 2024)	2024	Confusion Matrix	Kerangka tabel kontingensi untuk membaca pola kesalahan klasifikasi dan dasar perhitungan *accuracy*, *precision*, *recall*, serta *F1-score*.

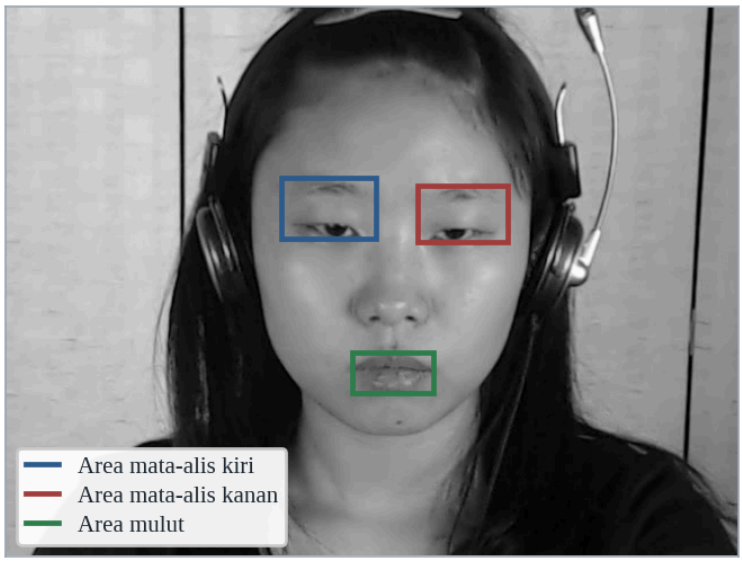
Tabel 2.1 Penelitian terdahulu yang dijadikan rujukan

Dari penelitian tersebut, estimasi pergerakan berbasis blok (POC-ABS) terbukti mampu merepresentasikan pergerakan mikro wajah secara cepat, dan pemodelan data tabular berbasis *retrieval* (TabR) terbukti unggul pada tugas klasifikasi data berukuran kecil hingga menengah. Keduanya belum dipertemukan untuk memodelkan kondisi *anxiety*, karena penelitian pengenalan ekspresi mikro masih berpusat pada emosi dasar yang tersedia dalam dataset standar. Celah inilah yang menjadi dasar penelitian ini.

2.2 Dasar Teori

2.2.1 Ekspresi Mikro Wajah

Ekspresi wajah merupakan kanal komunikasi nonverbal utama yang mengungkap keadaan emosional seseorang, dan umumnya terbentuk tanpa disadari sebagai reaksi atas emosi yang sedang dialami (Dawel et al., 2025). Perubahan ekspresi terpusat pada area seperti alis, kelopak mata, dan mulut, yang berperan penting dalam menyampaikan informasi emosional (Kim et al., 2022).



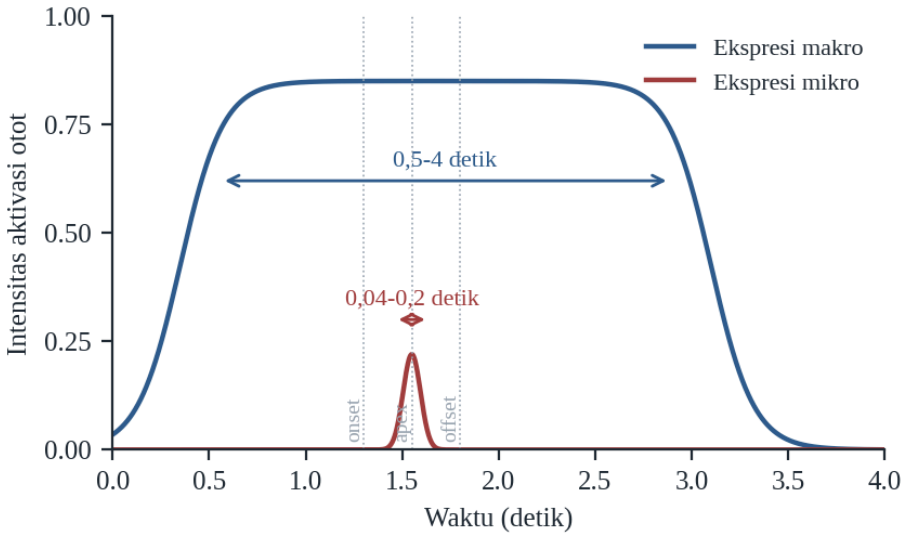
Gambar 2.1 Ekspresi Wajah

Sumber: data CASME II

Berdasarkan karakteristik kemunculannya, ekspresi wajah dibedakan menjadi ekspresi makro dan ekspresi mikro. Ekspresi makro melibatkan perubahan pada hampir seluruh bagian wajah sehingga relatif mudah diamati, sedangkan ekspresi mikro merupakan gerakan otot wajah yang muncul tanpa disengaja dengan durasi sangat singkat dan intensitas gerakan yang halus, berlangsung sekitar 0,04 hingga 0,2 detik, serta hanya tampak pada sebagian kecil bagian wajah (Choirina et al., 2022).

Ekspresi mikro (*micro-expression*) muncul ketika seseorang berupaya menutupi atau menekan emosi yang sesungguhnya, sehingga gerakan wajah yang tampak bersifat spontan dan sukar dikendalikan. Berbeda dari ekspresi makro yang dapat dimanipulasi secara sadar, ekspresi mikro menyingkap emosi autentik melalui perubahan otot wajah yang sangat halus dan berdurasi pendek (Ben et al., 2022). Intensitas pergerakan ototnya terbukti jauh lebih kecil daripada ekspresi makro, sehingga ekspresi yang muncul sering kali tidak membentuk pola wajah yang utuh dan sulit dikenali secara visual (Lu et al., 2022). Ekspresi ini lahir dari interaksi antara sistem motorik emosional dan sistem kontrol volunter wajah, sehingga pergerakan ototnya tidak selalu terorganisasi secara penuh seperti pada ekspresi sadar (Dong et al., 2022). Dengan demikian, ekspresi mikro lebih tepat dipahami

sebagai indikator kebocoran emosi yang kuat, dan sifatnya yang halus serta lokal inilah yang menjadikannya sukar dikenali secara kasat mata.



Gambar 2.2 Micro-expressions

2.2.2 Kecemasan dan Ekspresi Mikro

Kecemasan (*anxiety*) dipahami sebagai perasaan antisipatif terhadap kemungkinan munculnya situasi yang menakutkan, yang mendorong individu bersiap bertindak, meskipun pada kenyataannya ancaman tersebut tidak benar-benar terjadi dan tidak terikat pada objek atau kondisi tertentu yang perlu dihindari. Secara psikologis, kondisi ini berbeda dari *fear*, sebab *fear* muncul sebagai respons terhadap ancaman yang nyata dan spesifik serta memicu reaksi cepat seperti *fight or flight*, sedangkan *anxiety* berkaitan dengan ancaman yang tidak terdefinisi dengan jelas dan menghasilkan kewaspadaan yang berlangsung terus-menerus (Hur et al., 2020).

Kecemasan berubah menjadi kondisi abnormal ketika intensitas dan durasinya tidak sebanding dengan ancaman yang dihadapi atau justru muncul tanpa sebab yang jelas, sehingga tidak lagi dapat dimaknai sebagai respons adaptif terhadap lingkungan. Pada kondisi itu, kecemasan dapat berkembang menjadi gangguan psikologis yang mengganggu fungsi sosial, pekerjaan, serta aktivitas sehari-hari individu (Javaid et al., 2023). Tingginya prevalensi gangguan kecemasan di Indonesia menunjukkan bahwa kecemasan abnormal merupakan persoalan kesehatan mental yang serius, terutama pada kelompok remaja dan pelajar (Wahdi et al., 2025).

Dalam interaksi sosial, kecemasan yang berlangsung terus-menerus tidak selalu diungkapkan secara jelas melalui ekspresi wajah yang mudah dikenali. Individu dengan *anxiety* cenderung melakukan regulasi emosi dengan menahan ekspresi negatif guna menjaga citra diri dan menyesuaikan diri dengan lingkungan sosial, sehingga tanda-tanda visual kecemasan sering kali tidak tampak secara eksplisit (Lei et al., 2024). Sebagai konsekuensinya, respons emosional yang berkaitan dengan kecemasan lebih sering muncul dalam bentuk aktivasi otot wajah yang tidak disengaja, berintensitas sangat rendah, dan berdurasi singkat. Pola kemunculan tersebut sejalan dengan karakteristik *micro-expression*, yaitu ekspresi wajah yang timbul ketika individu berupaya menyembunyikan emosi yang sesungguhnya, namun tetap menunjukkan kebocoran emosi secara spontan (Zhao et al., 2023). Dalam kerangka *micro-expression*, perubahan tersebut tampak pada area berikut:

1. Area mata, khususnya perubahan halus di sekitar bagian bawah mata yang mencerminkan peningkatan kewaspadaan.
2. Area sudut bibir (*lip corner*), yang menunjukkan ketegangan ringan sebagai respons terhadap ketidaknyamanan emosional.

Perubahan pada area-area tersebut bersifat sementara dan sulit dikenali secara kasat mata, sehingga lebih relevan dianalisis dalam kerangka *micro-expression* dan pendekatan visual yang sensitif terhadap perubahan kecil pada fitur wajah (Sharma et al., 2024).

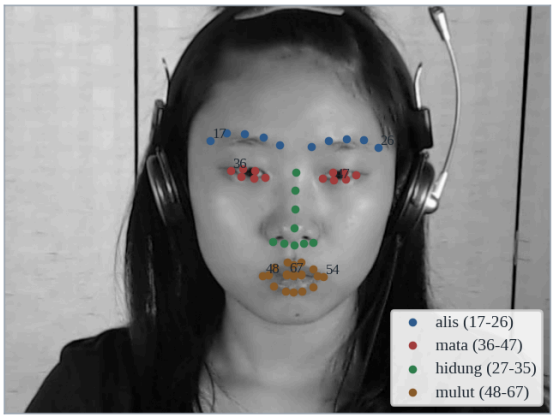
Kecemasan juga tidak selalu berhenti ketika situasi pemicunya berakhir. Studi menunjukkan bahwa seseorang tetap melakukan evaluasi berulang atas pengalaman ujian yang telah dijalani, dan *post-event processing* teramati muncul secara bermakna setelah situasi ujian serta berkaitan dengan tingkat kecemasan yang dialami (Möcklinghoff et al., 2024). Temuan tersebut mengindikasikan bahwa gangguan kecemasan dapat berlangsung sebelum maupun sesudah stimulus pemicunya berakhir.

2.2.3 Facial Landmark dan Dlib

Deteksi wajah merupakan tahap awal dalam pemrosesan citra wajah yang bertujuan mengenali keberadaan wajah sekaligus memisahkan area wajah dari latar belakang,

sehingga analisis berikutnya hanya tertuju pada wilayah wajah yang relevan (Li et al., 2022). Pada analisis *micro-expression*, hasil deteksi wajah menjadi *facial region* yang memasok tahap selanjutnya, yaitu pelokalan titik fitur dan ekstraksi pergerakan otot wajah yang sangat halus (Choirina et al., 2022).

Dlib merupakan pustaka *open-source* yang menyediakan fungsi deteksi wajah dan pelokalan titik *landmark* wajah, sehingga menopang proses pemrosesan lanjutan dalam analisis wajah. Melalui pendekatan *facial landmark*, komponen wajah seperti mata, alis, dan mulut dapat diidentifikasi sebagai bagian dari tahap pra-pemrosesan (Bachtiar & Wafi, 2021). Representasi fitur berbasis *landmark* juga menjadi pilihan yang lazim pada data berukuran kecil, karena membuat pengklasifikasi bekerja pada fitur terstruktur dan bukan pada citra mentah (Li et al., 2022). Representasi *facial landmark* yang digunakan pada penelitian ini ditunjukkan pada gambar berikut.



Gambar 2.3 Facial Landmark Dlib

Sumber: data CASME II

Gambar tersebut memperlihatkan representasi *facial landmark* yang dipakai, dengan setiap titik mewakili posisi geometris tertentu pada wajah. Titik-titik *landmark* ini dimanfaatkan untuk memetakan struktur wajah, seperti area alis, mata, hidung, dan mulut, sehingga pergerakan atau perubahan pada bagian wajah dapat dianalisis secara lebih terperinci.

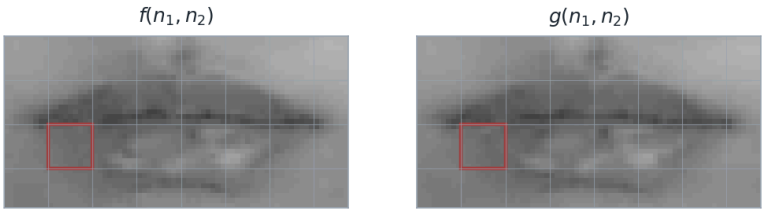
2.2.4 Phase Only Correlation with All Block Search (POC-ABS)

Phase Only Correlation with All Block Search (POC-ABS) merupakan metode estimasi pergerakan berbasis *block matching* untuk mendeteksi pergerakan wajah yang sangat halus dan berdurasi singkat. Metode ini membandingkan setiap

blok pada dua *frame* berurutan untuk menentukan ada atau tidaknya pergerakan translasi pada blok yang sama. Blok yang identik tidak menghasilkan vektor gerak, sedangkan blok yang berbeda menghasilkan vektor gerak yang merepresentasikan pergerakan halus pada area wajah tertentu. Vektor gerak tersebut menjadi fitur pergerakan yang menggambarkan kebocoran ekspresi yang muncul secara spontan dan berintensitas rendah (Rosiani et al., 2020).

POC bekerja pada domain frekuensi melalui *Fast Fourier Transform* (FFT). Informasi fase dimanfaatkan untuk menentukan pergeseran antar blok karena fase merepresentasikan posisi relatif objek, sedangkan amplitudo lebih dipengaruhi oleh intensitas pencahayaan (Rosiani et al., 2020). Dengan cara ini, pergeseran antar blok dapat dihitung secara efisien tanpa terpengaruh perbedaan terang citra.

Proses estimasi pergerakan dilakukan dengan membagi citra menjadi blok-blok kecil yang dianalisis secara lokal. Dua *frame* berurutan, yaitu n_1 dan n_2, dibandingkan pada blok yang bersesuaian untuk mengamati adanya pergeseran, sebagaimana diilustrasikan pada Gambar 2.4.



Gambar 2.4 Contoh dua frame untuk n1 dan n2

Sumber: data CASME II

Misalkan dua *frame* berukuran $N_1 \times N_2$ dinyatakan sebagai $f(n_1, n_2)$ dan $g(n_1, n_2)$. Transformasi Fourier Diskrit dari kedua *frame* tersebut dinyatakan sebagai berikut.

$$F(k_1, k_2) = \sum_{n_1, n_2} f(n_1, n_2) W_{N_1}^{k_1 n_1} W_{N_2}^{k_2 n_2} = A_F(k_1, k_2) e^{j\theta_F(k_1, k_2)}$$

$$G(k_1, k_2) = \sum_{n_1, n_2} g(n_1, n_2) W_{N_1}^{k_1 n_1} W_{N_2}^{k_2 n_2} = A_G(k_1, k_2) e^{j\theta_G(k_1, k_2)}$$

dengan A_F dan A_G menyatakan amplitudo spektrum, sedangkan θ_F dan θ_G menyatakan informasi fase.

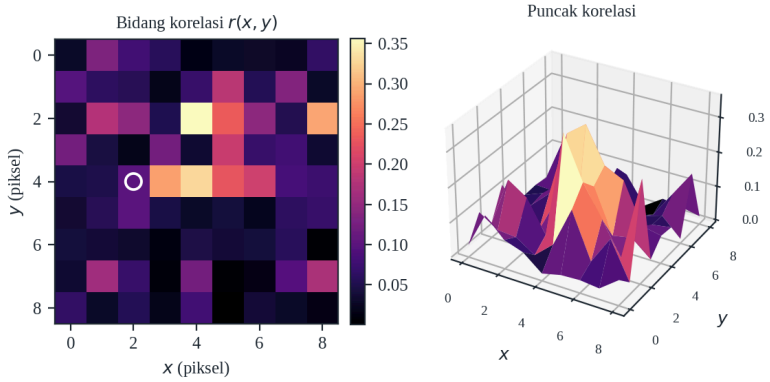
Cross spectrum $R(k_1, k_2)$ diperoleh dengan menormalisasi hasil perkalian $F(k_1, k_2)$ dan konjugat kompleks $G(k_1, k_2)$. Normalisasi ini menghilangkan pengaruh amplitudo sehingga hanya informasi fase yang dipertahankan.

$$R(k_1, k_2) = \frac{F(k_1, k_2)G^*(k_1, k_2)}{|F(k_1, k_2)|\ |G(k_1, k_2)|} = e^{j(\theta_F(k_1,k_2) - \theta_G(k_1,k_2))}$$

Fungsi *Phase Only Correlation* $r(n_1, n_2)$ diperoleh melalui transformasi Fourier balik dua dimensi dari $R(k_1, k_2)$.

$$r(n_1, n_2) = \frac{1}{N_1 N_2} \sum_{k_1, k_2} R(k_1, k_2) W_{N_1}^{-k_1 n_1} W_{N_2}^{-k_2 n_2}$$

Nilai maksimum $r(n_1, n_2)$ menunjukkan tingkat kemiripan fase antara kedua *frame*, sedangkan posisi puncaknya menunjukkan estimasi pergeseran translasi. Jika kedua blok identik, puncak korelasi bernilai satu dan tajam sempurna; sebaliknya, nilai korelasi turun secara signifikan ketika kedua blok berbeda.



Gambar 2.5 Proses POC deteksi pergerakan dari gambar contoh 2.4

Sumber: hasil pengolahan penulis pada data CASME II

Hasil perbandingan pada Gambar 2.5 menghasilkan dua fitur utama, yaitu koordinat X dan Y, yang merepresentasikan pergeseran piksel dari titik pusat menuju posisi baru setelah terjadinya pergeseran antar-*frame*. Berdasarkan kedua nilai tersebut diturunkan dua fitur tambahan, yaitu sudut pergeseran (*theta*) dan besar pergeseran (*magnitude*).

$$\theta_{\text{rad}} = \arctan\left(\frac{y}{x}\right) \quad \theta_{\text{deg}} = \theta_{\text{rad}} \cdot \frac{180}{\pi} \quad \theta = \theta_{\text{deg}} + (360 \cdot (y < 0))$$

$$m = \sqrt{x^2 + y^2}$$

Sudut θ menyatakan arah vektor pergeseran terhadap sumbu X, sedangkan *magnitude* m menyatakan panjang vektor pergeseran. Nilai *magnitude* yang kecil merepresentasikan pergerakan mikro atau perubahan yang sangat halus. Kombinasi fitur X, Y, θ, dan m inilah yang disusun menjadi dataset untuk tahap klasifikasi.

Secara ringkas, tahapan POC-ABS pada setiap pasangan blok adalah sebagai berikut.

1. Citra dibagi menjadi blok berukuran tetap, kemudian blok yang bersesuaian dari *frame* referensi dan *frame* berikutnya dipotong untuk dibandingkan.
2. Setiap blok dikenai *window* Hanning dua dimensi untuk mengurangi efek tepi, lalu ditransformasikan ke domain frekuensi menggunakan FFT2.
3. Korelasi fase dihitung dan ditransformasikan balik menjadi matriks korelasi spasial $r(x, y)$.
4. Titik puncak $r(x, y)$ dideteksi untuk memperoleh pergeseran blok d_x dan d_y, yang selanjutnya diubah menjadi *magnitude* dan sudut pergeseran.
5. Setiap blok menghasilkan fitur berupa posisi dan vektor gerak, seperti contoh pada Tabel 2.2.

Blok	**X**	**Y**	**Magnitude**	**Theta**
10	10	10	2.00	0° (kanan)
22	17	17	2.24	−63° (kanan bawah)
41	10	31	2.00	90° (bawah)
46	45	31	1.41	−45° (kanan bawah)
50	63	31	2.00	180° (kiri)

Tabel 2.2 Contoh hasil ekstraksi fitur

Blok dengan vektor panjang dan arah yang jelas menunjukkan adanya pergerakan nyata, sedangkan blok dengan $d_x = d_y = 0$ menandakan tidak adanya pergerakan. Visualisasi vektor gerak dilakukan menggunakan panah (*quiver*), dengan X dan Y sebagai posisi tengah blok serta d_x dan d_y sebagai komponen arah vektornya, dan panah hanya ditampilkan pada blok yang memiliki pergerakan.

2.2.5 Data Tabular dan Tabular Retrieval Network (TabR)

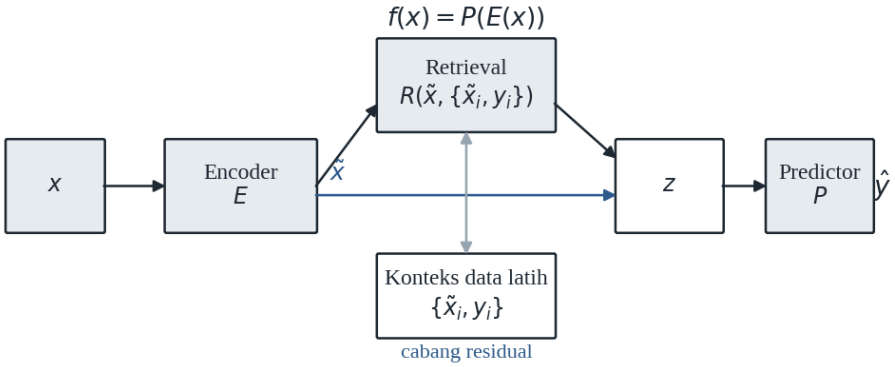
Data tabular merupakan representasi data dalam struktur baris dan kolom, dengan setiap baris merepresentasikan satu objek pengamatan dan setiap kolom merepresentasikan fitur yang menggambarkan karakteristik objek tersebut (Arik & Pfister, 2021). Representasi ini merupakan tipe data yang paling umum dijumpai dalam aplikasi pembelajaran mesin di dunia nyata (Gorishniy et al., 2024). Pada penelitian ini, hasil ekstraksi POC-ABS disusun sebagai data tabular, yaitu setiap sampel ekspresi menjadi satu baris dan setiap fitur pergerakan pada tiap area pengamatan menjadi kolom. Dengan demikian, informasi pergerakan mikro yang halus dapat dimodelkan secara eksplisit tanpa bergantung pada struktur spasial citra maupun urutan temporal video.

Tabular Retrieval Network (TabR) merupakan model *deep learning* yang dirancang khusus untuk permasalahan klasifikasi dan regresi pada data tabular dengan mengintegrasikan mekanisme *retrieval* ke dalam jaringan *feed-forward*. TabR dikembangkan untuk mengatasi keterbatasan model *deep learning* tabular konvensional yang sering kali masih tertinggal performanya dibandingkan metode *gradient-boosted decision trees* (GBDT). Dengan memanfaatkan prinsip *retrieval-augmented learning*, TabR memperkaya representasi suatu sampel dengan informasi dari sampel lain yang paling relevan dalam data latih, sehingga prediksi tidak hanya bergantung pada bobot model, tetapi juga pada konteks lokal antar sampel (Gorishniy et al., 2024).

Mekanisme *retrieval* pada TabR dijalankan menggunakan *Facebook AI Similarity Search* (FAISS), yaitu pustaka *open-source* untuk mencari vektor yang paling mirip terhadap suatu *query* pada ruang berdimensi tinggi secara efisien (Johnson et al., 2021). FAISS membangun indeks berbasis *Approximate Nearest Neighbor* (ANN) sehingga pencarian tetangga terdekat tidak perlu menghitung jarak terhadap seluruh vektor. Pada penelitian ini, FAISS berperan sebagai infrastruktur pencarian kandidat terdekat di dalam modul *retrieval* TabR, bukan sebagai model pembelajaran tersendiri.

Pendekatan *retrieval* pada TabR memungkinkan model menangkap hubungan lokal yang sulit direpresentasikan melalui transformasi global, terutama

pada data tabular berukuran kecil hingga menengah. Studi empiris menunjukkan bahwa TabR mencapai performa rata-rata terbaik di antara model *deep learning* tabular dan pada sejumlah dataset mampu melampaui GBDT, khususnya pada tugas klasifikasi (Gorishniy et al., 2024; Pasaribu et al., 2024).



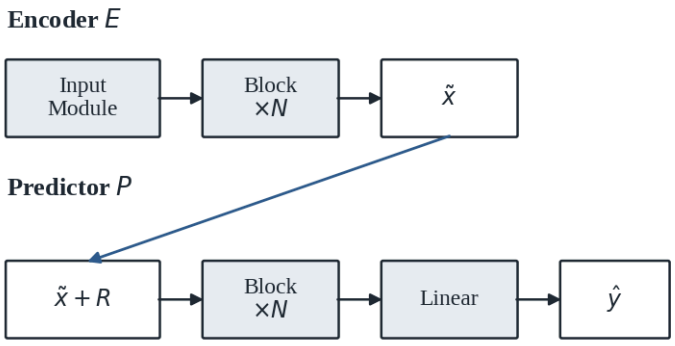
Gambar 2.6 Arsitektur TabR

Sumber: diadaptasi dari (Gorishniy et al., 2024)

Berdasarkan Gambar 2.6, TabR dikembangkan dari jaringan *feed-forward* $f(x) = P(E(x))$ dengan menambahkan modul *retrieval* R setelah *encoder* dalam bentuk cabang residual. *Encoder* memetakan sampel target x dan sampel kandidat $\{x_i\}$ ke ruang representasi laten yang sama, sehingga diperoleh $\tilde{x} = E(x)$ dan $\tilde{x}_i = E(x_i)$. Modul *retrieval* kemudian mengambil informasi dari sampel kandidat yang paling mirip dan menggabungkannya dengan representasi sampel target.

$$z = \tilde{x} + R(\tilde{x}, \{\tilde{x}_i, y_i\}) \quad \hat{y} = P(z)$$

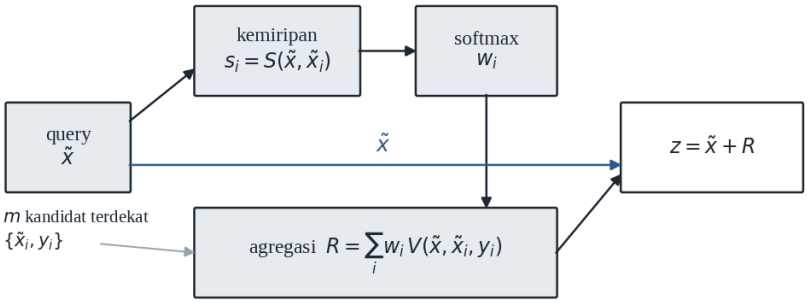
Dengan mekanisme ini, keputusan model tidak hanya bergantung pada bobot jaringan, tetapi juga pada konteks lokal antar sampel.



Gambar 2.7 Encoder dan Predictor

Sumber: diadaptasi dari (Gorishniy et al., 2024)

Berdasarkan Gambar 2.7, *encoder* E dan *predictor* P pada TabR dirancang sebagai jaringan *feed-forward* sederhana. *Encoder* memproses data tabular melalui *Input Module*, lalu dilanjutkan beberapa *block* pemrosesan untuk menghasilkan representasi laten $\tilde{x}$. *Predictor* P memetakan representasi tersebut ke ruang keluaran melalui rangkaian *block* dan lapisan linear untuk menghasilkan prediksi akhir.



Gambar 2.8 Retrieval Module

Sumber: diadaptasi dari (Gorishniy et al., 2024)

Berdasarkan Gambar 2.8, modul *retrieval* R memilih sejumlah m sampel kandidat yang paling mirip dengan sampel target pada ruang laten. Nilai kemiripan $s_i = S(\tilde{x}, \tilde{x}_i)$ dinormalisasi dengan *softmax* untuk memperoleh bobot kontribusi

$$w_i = \frac{\exp(s_i)}{\sum_{j \in I_{\text{cand}}} \exp(s_j)}$$

Informasi dari sampel kandidat kemudian diagregasi menggunakan bobot tersebut,

$$R = \sum_{i=1}^{m} w_i \cdot V(\tilde{x}, \tilde{x}_i, y_i)$$

untuk memperkaya representasi laten sampel target sebelum dilakukan prediksi akhir.

2.2.6 Metrik Evaluasi

Kelas *anxiety* tinggi ditetapkan sebagai kelas positif dan *anxiety* rendah sebagai kelas negatif. Performa model diukur menggunakan *accuracy*, *precision*, *recall*, dan *F1-score* (Chicco & Jurman, 2023), yang dihitung menggunakan persamaan berikut.

1. *Accuracy*

$$\text{accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

2. *Precision*

$$\text{precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

3. *Recall*

$$\text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

4. *F1-Score*

$$F_1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

BAB III. METODOLOGI PENELITIAN

Bagian ini belum ditulis.

DAFTAR PUSTAKA

Arik, S. Ö., & Pfister, T. (2021). TabNet: Attentive Interpretable Tabular Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, *35*(8), 6679–6687. https://doi.org/10.1609/aaai.v35i8.16826

Bachtiar, F. A., & Wafi, M. (2021). Komparasi Metode Klasifikasi untuk Deteksi Ekspresi Wajah Dengan Fitur Facial Landmark. *Jurnal Teknologi Informasi dan Ilmu Komputer*, *8*(5), 949–956. https://doi.org/10.25126/jtiik.2021834434

Ben, X., Ren, Y., Zhang, J., Wang, S.-J., Kpalma, K., Meng, W., & Liu, Y.-J. (2022). Video-Based Facial Micro-Expression Analysis: A Survey of Datasets, Features and Algorithms. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *44*(9), 5826–5846. https://doi.org/10.1109/TPAMI.2021.3067464

Chicco, D., & Jurman, G. (2023). The Matthews Correlation Coefficient (MCC) Should Replace the ROC AUC as the Standard Metric for Assessing Binary Classification. *BioData Mining*, *16*(1), 4. https://doi.org/10.1186/s13040-023-00322-4

Choirina, P., Rosiani, U. D., & Fitriani, I. M. (2022). Pengenalan Ekspresi Mikro Wajah Berdasarkan Point Feature Tracking Menggunakan Fase Apex Pada Database Ekspresi Mikro. *Edu Komputika Journal*, *9*(1), 28–36. https://doi.org/10.15294/edukomputika.v9i1.56600

Dawel, A., Krumhuber, E. G., & Palermo, R. (2025). Faking It Isn't Making It: Research Needs Spontaneous and Naturalistic Facial Expressions. *Affective Science*. https://doi.org/10.1007/s42761-025-00320-1

Dong, Z., Wang, G., Lu, S., Li, J., Yan, W., & Wang, S.-J. (2022). Spontaneous Facial Expressions and Micro-Expressions Coding: From Brain to Face. *Frontiers in Psychology*, *12*, 784834. https://doi.org/10.3389/fpsyg.2021.784834

Gavrilescu, M., & Vizireanu, N. (2019). Predicting Depression, Anxiety, and Stress Levels from Videos Using the Facial Action Coding System. *Sensors*, *19*(17), 3693. https://doi.org/10.3390/s19173693

Gorishniy, Y., Rubachev, I., Kartashev, N., Shlenskii, D., Kotelnikov, A., & Babenko, A. (2024, May). TabR: Tabular Deep Learning Meets Nearest

Neighbors. *Proceedings of the 12th International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/2307.14338

Hur, J., Smith, J. F., DeYoung, K. A., Anderson, A. S., Kuang, J., Kim, H. C., Tillman, R. M., Kuhn, M., Fox, A. S., & Shackman, A. J. (2020). Anxiety and the Neurobiology of Temporally Uncertain Threat Anticipation. *Journal of Neuroscience*, *40*(41), 7949–7964. https://doi.org/10.1523/JNEUROSCI.0704-20.2020

Javaid, S. F., Hashim, I. J., Hashim, M. J., Stip, E., Samad, M. A., & Al Ahbabi, A. (2023). Epidemiology of Anxiety Disorders: Global Burden and Sociodemographic Associations. *Middle East Current Psychiatry*, *30*, 44. https://doi.org/10.1186/s43045-023-00315-3

Johnson, J., Douze, M., & Jégou, H. (2021). Billion-Scale Similarity Search with GPUs. *IEEE Transactions on Big Data*, *7*(3), 535–547. https://doi.org/10.1109/TBDATA.2019.2921572

Kim, M., Cho, Y., & Kim, S.-Y. (2022). Effects of Diagnostic Regions on Facial Emotion Recognition: The Moving Window Technique. *Frontiers in Psychology*, *13*, 966623. https://doi.org/10.3389/fpsyg.2022.966623

Larasati, S. S. A., Dewi, E. N. K., Farhansyah, B. H., Bachtiar, F. A., & Pradana, F. (2024). Penerapan Decision Tree dan Random Forest dalam Deteksi Tingkat Stres Manusia Berdasarkan Kondisi Tidur. *Jurnal Teknologi Informasi dan Ilmu Komputer*, *11*(5), 1043–1050. https://doi.org/10.25126/jtiik.2024117993

Lei, J., Leigh, E., Charman, T., Russell, A., & Hollocks, M. J. (2024). Exploring the Association between Social Camouflaging and Self- versus Caregiver-Report Discrepancies in Anxiety and Depressive Symptoms in Autistic and Non-Autistic Socially Anxious Adolescents. *Autism*, *28*(10), 2657–2674. https://doi.org/10.1177/13623613241238251

Li, Y., Wei, J., Liu, Y., Kauttonen, J., & Zhao, G. (2022). Deep Learning for Micro-Expression Recognition: A Survey. *IEEE Transactions on Affective Computing*, *13*(4), 2028–2046. https://doi.org/10.1109/TAFFC.2022.3205170

Lu, S., Li, J., Wang, Y., Dong, Z., Wang, S.-J., & Fu, X. (2022). A More Objective Quantification of Micro-Expression Intensity through Facial Electromyography.

Proceedings of the 2nd Workshop on Facial Micro-Expression: Advanced Techniques for Multi-Modal Facial Expression Analysis, 11–17. https://doi.org/10.1145/3552465.3555038

Möcklinghoff, S., Rapoport, O., & Neidhardt, E. (2024). Examining the Role of Post-Event Processing in Test Anxiety: Pilot Testing in Three Student Samples. *International Journal of Educational Research Open*, *7*, 100363. https://doi.org/10.1016/j.ijedro.2024.100363

Oh, Y.-H., See, J., Le Ngo, A. C., Phan, R. C.-W., & Baskaran, V. M. (2018). A Survey of Automatic Facial Micro-Expression Analysis: Databases, Methods, and Challenges. *Frontiers in Psychology*, *9*, 1128. https://doi.org/10.3389/fpsyg.2018.01128

Pasaribu, J., Yudistira, N., & Mahmudy, W. F. (2024). Tabular Data Classification and Regression: XGBoost or Deep Learning with Retrieval-Augmented Generation. *IEEE Access*, *12*, 186763–186774. https://doi.org/10.1109/ACCESS.2024.3518205

Prakoso, R. A., Widasari, E. R., & Nurfarida, I. (2026). Sistem Deteksi Stres Menggunakan Metode Support Vector Machine dengan Fitur RMSSD dan PNN50. *Jurnal Teknologi Informasi dan Ilmu Komputer*, *13*(3), 703–712. https://doi.org/10.25126/jtiik.2026133

Rosiani, U. D., Choirina, P., Muna, N., Mulyanto, E., Sumpeno, S., & Purnomo, M. H. (2020). A Novel Approach on Motion Estimation for Micro-Expression Recognition Using Phase Only Correlation with All Block Search (POC-ABS). *International Journal of Intelligent Engineering and Systems*, *13*(6), 546–559. https://doi.org/10.22266/ijies2020.1231.48

Sahu, N. K., Gupta, S., & Lone, H. R. (2025,). *AnxietyFaceTrack: A Smartphone-Based Non-Intrusive Approach for Detecting Social Anxiety Using Facial Features*. https://doi.org/10.48550/arXiv.2502.16106

Sharma, D., Singh, J., Sehra, S. S., & Sehra, S. K. (2024). Demystifying Mental Health by Decoding Facial Action Unit Sequences. *Big Data and Cognitive Computing*, *8*(7), 78. https://doi.org/10.3390/bdcc8070078

Wahdi, A. E., Astrini, Y. P., Setyawan, A., Fine, S. L., Ramaiya, A., Li, M., Wado, Y. D., Loi, V. M., Maravilla, J. C., Scott, J. G., Wilopo, S. A., & Erskine, H. E. (2025). Mental Health Service Use among Adolescents in Three Low- and Middle-Income Countries: An Analysis of the National Adolescent Mental Health Surveys. *Child and Adolescent Psychiatry and Mental Health*, *19*(Suppl 1), 84. https://doi.org/10.1186/s13034-025-00924-2

Yang, S., & Berdine, G. (2024). Confusion Matrix. *The Southwest Respiratory and Critical Care Chronicles*, *12*(53), 75–79. https://doi.org/10.12746/swrccc.v12i53.1391

Zhang, H., Feng, L., Li, N., Jin, Z., & Cao, L. (2020). Video-Based Stress Detection through Deep Learning. *Sensors*, *20*(19), 5552. https://doi.org/10.3390/s20195552

Zhao, G., Li, X., Li, Y., & Pietikäinen, M. (2023). Facial Micro-Expressions: An Overview. *Proceedings of the IEEE*, *111*(10), 1215–1235. https://doi.org/10.1109/JPROC.2023.3275192